Propuesta de trabajo por estudiantes

Los grupos que se decidan por la opción de proponer un trabajo práctico no listado en los puntos anteriores, deberán proponer un problema a resolver que involucre los temas vistos en la materia.

Es obligatorio que el trabajo involucre la implementación de una arquitectura de redes neuronal. Pudiendo realizar un trabajo de análisis del estado del arte y la utilización de soluciones preexistentes en “modo inferencia”

Es un requisito que el tema sea revisado y aprobado previamente por el Profesor a cargo.

Para estructurar mejor el trabajo, se sugiere que el mismo siga el ciclo de desarrollo de un proyecto de inteligencia artificial el cual cuenta de los siguientes pasos:

1. Definición del problema a resolver
2. Estado del arte y trabajos relacionadas
3. Definición de un conjunto de datos
4. Creación del modelo
5. Evaluación del modelo y sus hiper parámetros
6. Despliegue y optimización

Tener especial cuidado en sobre-dimensionar la solución ni querer abarcar un problema demasiado grande. Lo mejor es un problema de tamaño moderado planificando una solución que les permita aprender de una determinada área de estudio o arquitectura neuronal.

1. Definición del problema a resolver

Para esto se deben plantear claramente los objetivos y metas a alcanzar durante el desarrollo del trabajo práctico. Además, se deben plantear hipótesis y proponer una metodología de trabajo que permita alcanzar los objetivos.

El problema a resolver tiene que poder definirse concretamente, debe ser acotado y plausible de implementar en menos del 30% del tiempo designado para la entrega.

2. Estado del arte y trabajos relacionadas

Es menester que el planteo del tema y las propuestas de resolución se basen en bibliografía y artículos publicada con referato, es decir, no cuentan como estado del arte páginas web Wikipedia, Medium, TowardsDatascience, ElRiconDelVago, Blogspot, posteos en Linkedin o redes sociales, etc. En estos últimos casos, se recomiendo buscar siempre la referencia original y los artículos a dónde se hace mención.

Tener especial cuidado con ArXiv. En muchos casos, los artículos subidos a esta plataforma no fueron revisados todavía (no tienen referatos). Los autores de los trabajos suelen subir versiones preliminares de los artículos previas al envío a una revista o conferencia, en las cuales el trabajo podría ser rechazado, por lo que se recomienda hacer una búsqueda en internet para verificar el estado de publicación de los mismos.

Una fuente de trabajos para la exploración del estado del arte es

Google Scholar: https://scholar.google.com/

3. Definición del conjunto de datos

Una de las tareas más importantes de este proyecto es la creación o definición del conjunto de datos de imágenes (o video) a utilizar. Prestar especial atención, durante la confección del estado del arte, a menciones sobre dataset públicos o sitios web donde los autores liberan los conjuntos de datos.

El dataset de imágenes a utilizar deberá estar estrechamente ligado al problema a resolver y contar con anotaciones que permitan extraer métricas de evaluación durante la evaluación y testeo del modelo.

Pueden tomar fotos ustedes mismos, buscar imágenes en internet, pensar en alguna otra fuente de imágenes como kaggle, huggingface, paperswithcode, etc. Tener en cuenta, en caso de utilizar un dataset propio o con anotaciones distintas a las necesarias, que el grupo deberá agregar manualmente las etiquetas deseadas en un número significante de las mismas (este número dependerá del problema a resolver, consultar con el Profesor a cargo).

Luego de recolectar y etiquetar tu conjunto de datos, deberían dividirlo en conjuntos de entrenamiento, validación y prueba. Una regla general para

dividir conjuntos de datos es asignar el 70% de tus datos a entrenamiento, 10% a validación y 20% a prueba.

Listas de datasets públicos disponibles:

- Meta Pointer: A large collection organized by CV Datasets.
- Yet another Meta pointer
- ImageNet: a large-scale image dataset for visual recognition organized by WordNet hierarchy
- Vision-language datasets:
  - Visual Genome
  - Flickr30k
  - VQA v2
  - ADE20K
  - LAION
- SA-1B: dataset of a large number of images and segmentation masks to segment objects in those images
- COCO: large-scale object detection, segmentation, and captioning dataset
- Open Images: a dataset of ~9M images annotated with image-level labels, object bounding boxes, object segmentation masks, visual relationships, and localized narratives
- Cityscapes Dataset: This dataset focuses on semantic understanding of urban street scenes, with pixel-level annotations for various object classes such as cars, pedestrians, and roads
- DeepFashion: a large-scale clothes dataset containing over 800,000 diverse fashion images annotated with bounding boxes, clothing categories, and attributes
- Hugging face datasets: collection of generic datasets available on hugging face
- Objaverse: a large-scale 3D asset database
- SUN Database: a benchmark for scene recognition and object detection with annotated scene categories and segmented objects
- Places Database: a scene-centric database with 205 scene categories and 2.5 millions of labelled images
- NYU Depth Dataset v2: a RGB-D dataset of segmented indoor scenes
- Microsoft COCO: a new benchmark for image recognition, segmentation and captioning
- Flickr100M: 100 million creative commons Flickr images
- Labeled Faces in the Wild: a dataset of 13,000 labeled face photographs
- Human Pose Dataset: a benchmark for articulated human pose estimation
- YouTube Faces DB: a face video dataset for unconstrained face recognition in videos
- UCF101: an action recognition data set of realistic action videos with 101 action categories
- HMDB-51: a large human motion dataset of 51 action classes
- ActivityNet: A large-scale video dataset for human activity understanding
- Moments in Time: A dataset of one million 3-second videos

4. Creación del modelo

El desarrollo del modelo se deberá realizar en Python y se recomienda utilizar la librería PyTorch. Otras librerías pueden utilizarse si el grupo de trabajo lo considera pertinente pero la cátedra no se compromete a brindar soporte sobre las mismas.

Se espera que el modelo sea entrenado sobre el conjunto de datos propuesto anteriormente. Pueden considerar tres maneras diferentes de entrenarlo:

- **Entrenar desde cero**: Inicializar el modelo aleatoriamente y entrenarlo desde cero en tu conjunto de entrenamiento.
- **Extracción de características**: Inicializar el modelo usando pesos pre-entrenados, extraer características del modelo y entrenar un modelo lineal sobre las características extraídas. Esto puede implementarse de varias maneras: podés usar PyTorch para agregar una nueva capa al modelo, congelar todas menos la última capa y entrenar en PyTorch; también podés extraer características del modelo y guardarlas en algún formato, luego entrenar un clasificador lineal con otro paquete como scikit-learn.
- **Ajuste fino (Fine-Tuning)**: Inicializar el modelo usando pesos pre-entrenados en ImageNet; ajustar todo el modelo en tu conjunto de entrenamiento. Esto debería funcionar al menos tan bien como la extracción de características.

Es posible que necesites experimentar con diferentes optimizadores, tasas de aprendizaje, regularización y estrategias de aumento (augmentation) de datos

Se deberían mostrar las curvas de entrenamiento para los modelos, graficando la función de pérdida de entrenamiento por iteración, así como la precisión del modelo en los conjuntos de entrenamiento y validación en cada época.

5. Evaluación del modelo y sus hiper-parámetros

Analizar el rendimiento de los modelos propuesto mostrando ejemplos de clasificación o detección correcta/incorrecta, matrices de confusión y todo lo visto en clase. Discutir los resultados de los mejores modelos en el conjunto de pruebas y analizar cuán bien generalizan los mismos.

También se desea mostrar resultados cualitativos para analizar en detalle los casos buenos, malos y patológicos. Es necesario que propongan hipótesis o ideas de de cómo se comportan modelos de manera analizando los resultados de forma visual.