# Vision X

## Ver el entorno. Entenderlo. Escucharlo.

Anteojos de asistencia espacial que transforman video estéreo en direcciones, distancias y descripciones auditivas accesibles.



DETECTAR MEDIR ORIENTAR

**Una aplicación accesible. Un problema real de deep learning.**
Red propia de profundidad y cuatro modos: buscar, medir, describir y leer texto. Primero USB directo; luego wearable por Wi-Fi.



Render conceptual: armazón y carcasa sujetos a diseño, fabricación y pruebas.

01 / UNA NECESIDAD CONCRETA

# Entender lo que no se alcanza a ver.

VisionX busca comunicar información visual relevante a personas con visión reducida, monocular o nula, sin exigirles interpretar una pantalla.

**2.200 MILLONES** de personas tienen deterioro de la visión cercana o lejana en el mundo, según la OMS.

Contexto de salud pública: la cifra no equivale a usuarios evaluados de VisionX.

01

ENCONTRAR

### ¿Dónde dejé las llaves o la mochila?

Buscar elementos cotidianos mediante voz; confirmar con un bip al detectarlos.

02

MEDIR

### ¿A qué distancia está la silla?

Informar una distancia aproximada cuando el objeto sea visible y la medición resulte confiable.

03

COMPRENDER

### ¿Qué hay frente a mí en esta habitación?

Describir el entorno de manera breve: objetos presentes, direcciones y relaciones verificadas.

**Beneficio buscado:** ofrecer información auditiva bajo demanda que reduzca la incertidumbre al buscar pertenencias, reconocer objetos o explorar una escena. La respuesta debe ser corta, configurable y capaz de reconocer límites de confianza.

**Límite de seguridad:** prototipo académico. No sustituye bastón, perro guía, acompañamiento ni tecnologías de movilidad validadas clínicamente.

02 / INTERACCIÓN POR VOZ

# Cuatro modos, sin respuestas que se superpongan.

El usuario elige una acción. Un controlador activa un único modo audible y mantiene la detección, la geometría, el VLM y el OCR como servicios separados.

### 01 FIND MY OBJECT

**«Buscá mi mochila»**

Explora la imagen hasta encontrar el objetivo. Emite un bip sin esperar a la profundidad; después informa metros y dirección. «Guiame» da indicaciones mientras el objeto permanezca visible.

### 02 DISTANCIA A OBJETO

**«¿A cuánto está la silla?»**

Reconoce el objeto que está dentro del campo visual. Consulta la profundidad y su incertidumbre; responde en metros aproximados o pide aclaración cuando hay varios objetos.

### 03 DESCRIPCIÓN DEL ENTORNO

**«¿Qué tengo enfrente?»**

A pedido, un VLM (modelo que relaciona imagen y lenguaje) resume la escena, objetos principales y relaciones visibles. «Más detalle» amplía sin interrumpir la búsqueda.

### 04 TEXT READER · LECTURA

**«Leé este cartel»**

Captura un frame estable, localiza texto con OCR, reconoce palabras y las reproduce por voz. Puede pedir acercar o centrar el texto si la imagen no es legible.

**Reglas de funcionamiento:** «Cancelar» vuelve a espera; una orden nueva cambia de modo y cancela tareas pendientes. «Guiame» es submodo de búsqueda, no un modo permanente. Sin IMU: si el objeto sale de la imagen, se vuelve a buscar.

03 / QUÉ ENTREGAMOS Y QUÉ EXTENDEMOS

# Diez capacidades organizadas por prioridades.

Los cuatro modos se construyen con módulos compartidos. Siete capacidades integran la demostración objetivo, una queda como meta adicional y dos como extensiones futuras.

01 ENTREGA
### Depth Vision
Mapa estéreo y consulta de distancia en metros.

02 ENTREGA
### Object Recognition
Detectar y segmentar objetos visibles.

03 ENTREGA
### Voice Assistant
Activar, cancelar y responder por voz.

04 ENTREGA
### Hybrid Depth
CNN propia: refinamiento e incertidumbre.

05 ENTREGA
### Find My Object
Bip, búsqueda y guía mientras haya visión.

06 ENTREGA
### Spatial Audio
Indicar izquierda/derecha, arriba/abajo.

07 EXTENSIÓN
### Object Memory
Recordar objetos fuera de la cámara.

08 META
### Near Object Alert
Avisos de cercanía configurables.

09 ENTREGA
### Text Reader
Modo lectura OCR de carteles y etiquetas.

10 EXTENSIÓN
### Semantic 3D Map
Reconstrucción persistente y SLAM.

**Lectura de alcance:** los modos BUSCAR, DISTANCIA, DESCRIBIR y TEXT READER se incluyen en la versión de PC. Near Object Alert se intentará si las pruebas de seguridad y latencia son satisfactorias. Memoria fuera de cámara y SLAM no se prometen para la entrega.

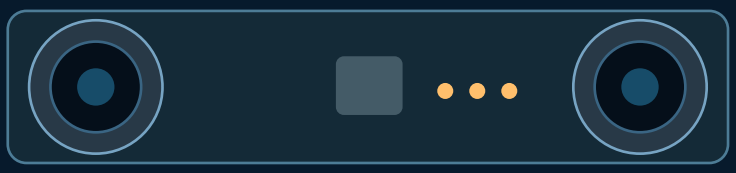
04 / COMPONENTES ELEGIDOS

# Hardware real, compacto y verificable.

La captura se concentra en una cámara USB UVC con dos sensores sincronizados; la Raspberry se incorpora solo al pasar al dispositivo portátil.

## ELP-USB3D1080P02-H120

Módulo estéreo USB · elegido para VisionX



2 lentes · 2 sensores JX-F35 · USB 2.0 UVC

INTERFACES
UVC · USB 2.0

RESOLUCIÓN ANUNCIADA
3840 × 1080 SBS

LENTES
125° horiz. aprox.

PLACA
80 × 16,5 mm

### Raspberry Pi 5 · 2 GB

BCM2712 + controlador RP1. Captura USB, Wi-Fi, Bluetooth y alimentación portátil; no ejecuta la CNN.

### Notebook con GPU

Entrena SpatialDepth-Lite y ejecuta detección, profundidad, VLM opcional y dashboard.

### AirPods / auriculares

Reproducción de bip y voz. Captura de micrófono por Bluetooth: validar; alternativa USB.

### Power bank + soporte

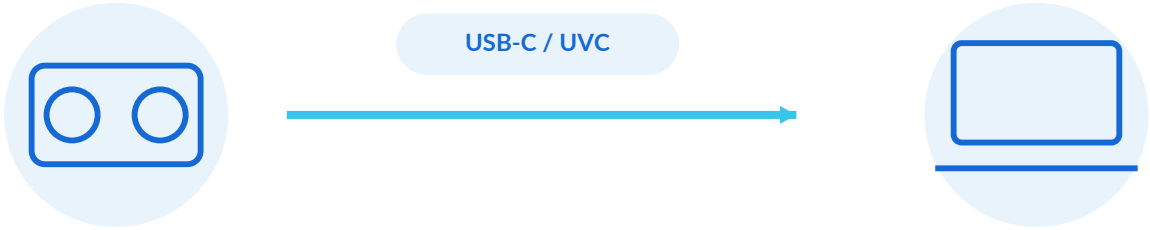
Batería USB-C apropiada, refrigeración y arnés pectoral. La montura solo lleva cámara y cable.

**Exclusión explícita:** no agregaremos giroscopio ni IMU. Las indicaciones de giro dependen de ver el objeto en imágenes recientes. No usaremos cables CSI ni sensores de orientación adicionales.

05 / ETAPA A

# Primero, un laboratorio funcional.

Antes de imprimir un armazón, todo el núcleo académico puede probarse con la ELP conectada directamente a la notebook.




**Cámara ELP**
Par estéreo en formato lado a lado (SBS).

**Notebook**
Captura, redes, geometría, dashboard y audio.

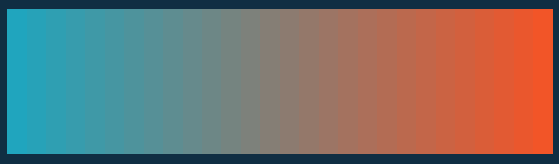
## DASHBOARD EN TIEMPO REAL

RGB / OBJETOS



**Mochila**
Conf. 0,92

DISPARIDAD / PROFUNDIDAD
0,5 m — 5 m



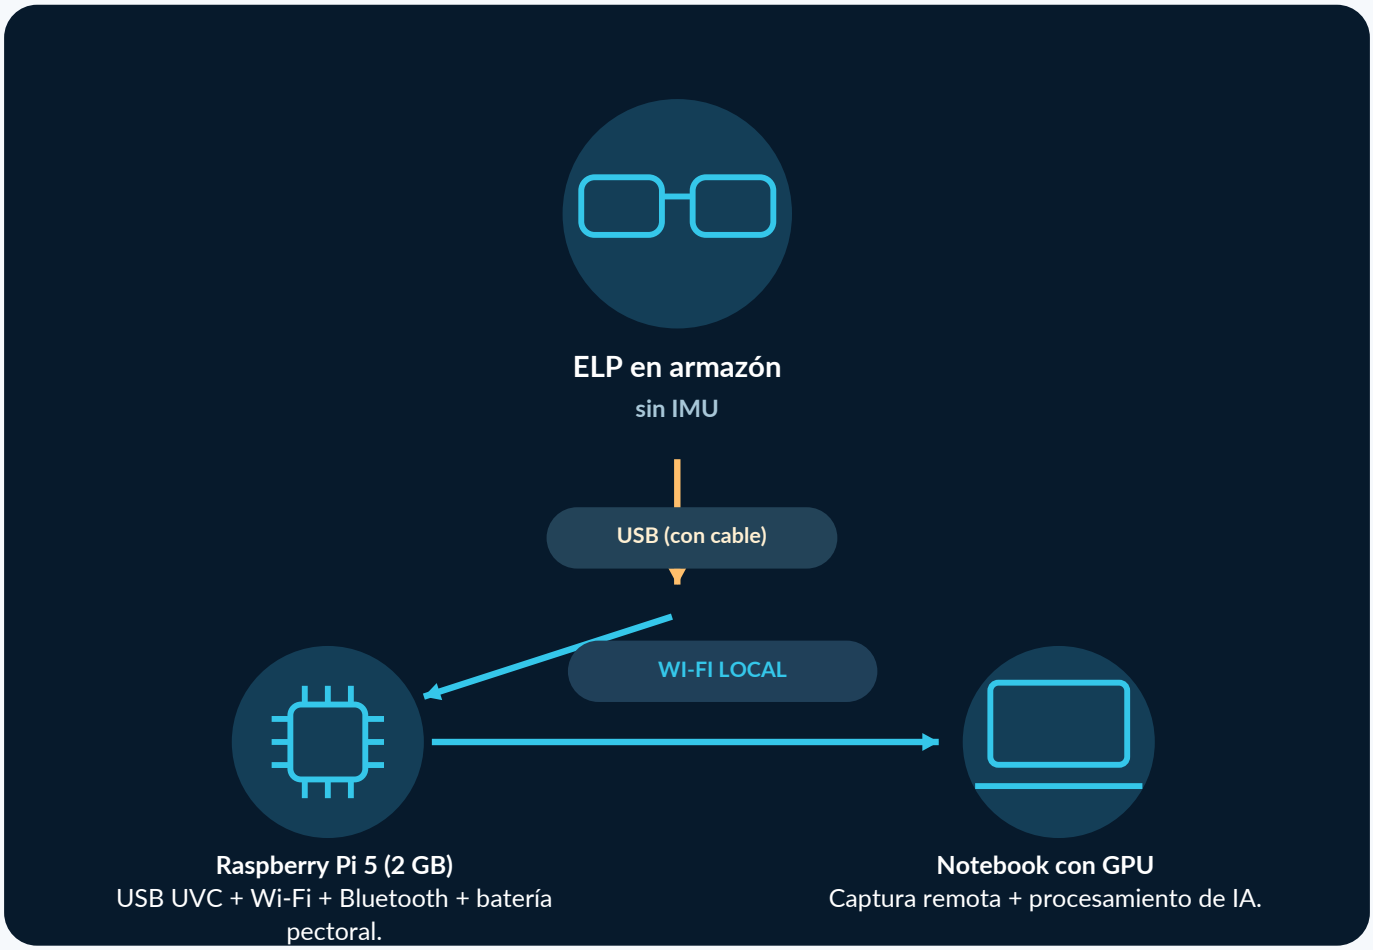
| FPS | MAE | P95 | CONF |
|---|---|---|---|
| captura | profundidad | latencia | incertidumbre |

Panel conceptual: los números se reemplazarán por mediciones reales, sin fingir precisión ni FPS previos al experimento.

06 / ETAPA B

# Después, wearable sin cable a la PC.

La misma cámara y el mismo software de IA; cambia solamente el transporte de los frames y el soporte físico.




### Voz y respuestas

AirPods conectados a la Raspberry por Bluetooth; la notebook devuelve eventos y audio sintetizado (TTS). Verificar el micrófono Bluetooth: si falla, micrófono USB discreto cerca de la boca.

**Lo inalámbrico:** la Raspberry no lleva un cable hasta la notebook; transmite video por Wi-Fi. **Lo cableado:** la cámara sí se conecta a la Raspberry por USB, y la batería alimenta el conjunto del pecho.

07 / ARQUITECTURA DE EJECUCIÓN

# Una cámara; cuatro tareas independientes.

No ejecutamos todos los modelos pesados para cada imagen. El controlador de estados selecciona qué necesita el usuario, mientras una cola corta conserva los frames más recientes.

**CONTROLADOR DE MODOS · prioridad de respuesta**

ESPERA | BUSCAR | DISTANCIA | DESCRIBIR | LEER

BUSCAR

### DETECCIÓN NEURONAL

YOLO es una red preentrenada que localiza objetos en cada imagen. Si coincide con el objetivo pedido y supera el umbral de confianza, enviamos el bip inmediatamente. Después consultamos profundidad para decir dónde está.

BIP

DISTANCIA

### GEOMETRÍA + NUESTRA CNN

StereoSGBM compara ambas vistas para estimar disparidad; SpatialDepth-Lite corrige ese mapa y estima incertidumbre. Con la calibración convertimos la disparidad a metros. Una medición poco fiable no se verbaliza.

METROS

DESCRIBIR

### MODELO VISIÓN-LENGUAJE

Un VLM preentrenado recibe una imagen reciente y, cuando sea útil, detecciones y distancias verificadas. Resume el entorno; no debe inventar relaciones ni cifras que no estén sustentadas. Se invoca únicamente a pedido.

CONTEXTO

TEXT READER

### OCR + SÍNTESIS DE VOZ

OCR significa reconocimiento óptico de caracteres. Se congela un frame nítido, se detectan zonas con letras y se reconoce el texto con un modelo preentrenado, por ejemplo PaddleOCR; luego TTS lo lee en voz alta.

LECTURA

**No se pisan:** una única salida de audio, cancelación al cambiar de modo, descarte de frames viejos y prioridades: bip > respuesta corta > descripción/lectura.

08 / LA INVESTIGACIÓN NEURONAL

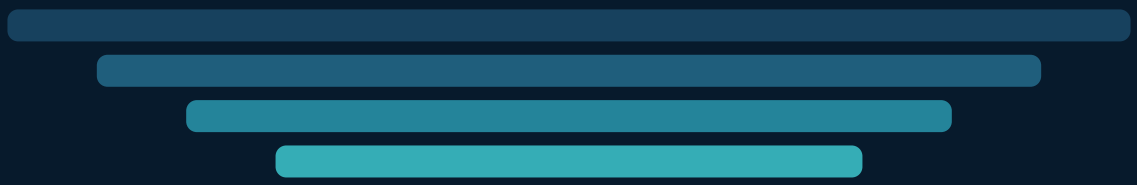
# SpatialDepth-Lite: una CNN que corrige el estéreo.

La contribución propia no es conectar APIs: entrenamos una red compacta para refinar la disparidad por píxel, preservar bordes y estimar cuándo su predicción puede fallar.

### ¿QUÉ VE LA RED? · SIETE CANALES ALINEADOS

**RGB izquierdo (3)**: texturas y contornos. **SGBM (1)**: disparidad inicial calculada entre las dos cámaras. **Máscara (1)**: píxeles sin correspondencia válida. **Chequeo L/R (1)**: desacuerdo al buscar el mismo punto de izquierda a derecha y viceversa. **Gradiente (1)**: zonas donde cambia el brillo y suelen existir bordes de objetos.

### CNN U-NET COMPACTA + CORRECCIÓN RESIDUAL



**Encoder:** convoluciones que extraen patrones de vecindarios cada vez mayores. **Decoder:** devuelve esos patrones a resolución de píxel. **Conexiones skip:** recuperan detalles finos. **Residual:** corrige el valor de SGBM en vez de aprender todo desde cero.

### SALIDA A · MAPA CORREGIDO

Predice d_final, en píxeles, para convertirla a Z=fB/d tras la calibración. Debe tratar por separado regiones sin dato estéreo.

### SALIDA B · INCERTIDUMBRE

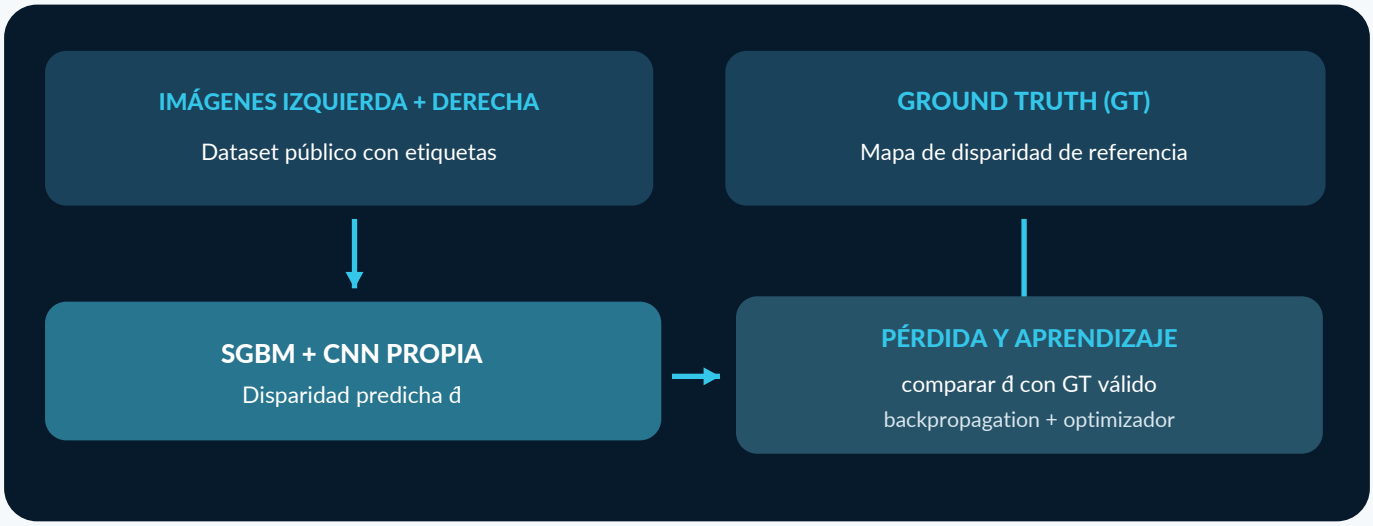
Estima el nivel de error esperable por píxel. Luego comprobamos si las zonas marcadas como dudosas fallan más en los tests.

**¿Por qué no ejecutar modelos gigantes en vivo?** Una CNN reducida puede aprovechar el contexto donde SGBM falla (pared lisa, oclusiones, reflejos) con menor costo que un teacher grande. La detección y el OCR usan modelos preentrenados aparte; **la CNN propia es el objeto de entrenamiento y evaluación académica**.

09 / ENTRENAMIENTO DESDE CERO

# Supervisado: ¿de dónde sale la respuesta correcta?

Entrenar significa modificar los pesos de SpatialDepth-Lite con ejemplos cuyo mapa de disparidad real ya conocemos. La estimación de SGBM es entrada; la etiqueta la aporta el dataset.




### 01 Preparar

Rectificamos cada par, generamos SGBM y canales auxiliares. Reescalamos píxeles y disparidades con la misma transformación.

### 02 Medir el error

Smooth L1 (Huber) compara cada disparidad predicha con el GT únicamente donde la referencia es válida; no aprende a copiar SGBM.

### 03 Aprender confianza

La segunda cabeza estima incertidumbre con pérdida probabilística; comprobamos su calibración para no anunciar cifras engañosas.

### 04 Evitar el sobreajuste

Separamos entrenamiento/validación/prueba por escena o sesión. Elegimos el checkpoint según validación y medimos al final en test intacto.

**Ejemplo:** si SGBM estima 16 px y el GT marca 20 px, la CNN podría aprender a producir 19 px, reduciendo el error de 4 a 1 px. Es un ejemplo didáctico, no un resultado obtenido. Al terminar congelamos los pesos: **en los lentes solo se hace inferencia**.

10 / DATOS, PRUEBAS Y MEJORAS

# Entrenamos con datos públicos; adaptamos sin etiquetar miles.

La mejora debe medirse sobre escenas que no estuvieron en el entrenamiento. Además, las cámaras de distintos datasets tienen focales y bases diferentes: no podemos mezclar disparidades sin normalizarlas.

SUPERVISADO

### InStereo2K

2.000 pares de entrenamiento y 50 de prueba con disparidad GT. Sirve para aprender correcciones espaciales reales y medir el error base.

GENERALIZACIÓN

### Middlebury 2014

Pares estéreo con calibración y disparidad de referencia; prueba materiales, bordes e iluminación fuera de nuestro entrenamiento.

TRANSFERENCIA

### ETH3D + ELP

ETH3D agrega escenas con referencia. En la ELP grabamos video sin etiquetas y algunas distancias medidas para validar el dispositivo.

### OPCIÓN 1 · TEACHER–STUDENT

Un modelo grande como FoundationStereo produce disparidades en imágenes sin GT. Filtramos pseudoetiquetas inconsistentes y entrenamos la CNN ligera para aproximar al teacher. La red grande trabaja **offline**, no bloquea el uso en vivo.

### OPCIÓN 2 · ADAPTACIÓN CON ELP

Grabamos interiores con la cámara final sin medir cada píxel. Usamos consistencia geométrica y pseudoetiquetas fiables para ajustar los pesos; comparamos antes y después con mediciones físicas independientes.

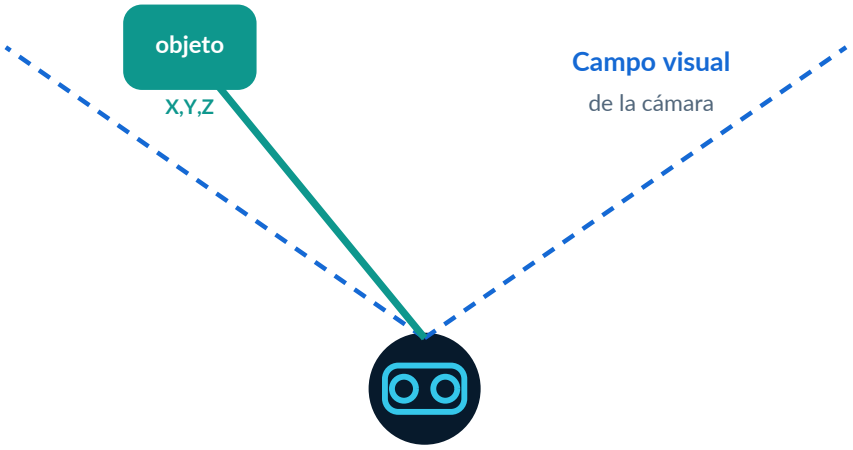
**Control experimental:** una pseudoetiqueta es una predicción, no verdad medida. Con GT evaluamos EPE (error medio de disparidad), MAE/RMSE de distancia y calibración de incertidumbre. Medimos también FPS y latencia total. Comparamos contra SGBM solo, filtrado clásico y variantes de la CNN (ablaciones).

11 / LOCALIZACIÓN ESPACIAL

# Izquierda, derecha, arriba, abajo... y metros.

En BUSCAR o DISTANCIA, la calibración convierte píxeles y profundidad en una dirección horizontal, otra vertical y una distancia aproximada; no hace falta IMU.

**Ejemplo conceptual:** mochila detectada más arriba y a la izquierda del centro óptico.




## Distancia axial

$Z = f \cdot B / d$

Con la disparidad d y la calibración: no equivale siempre a distancia radial.

## Ángulo horizontal

$\text{atan2}(X, Z)$

Indica cuánto orientar la cabeza a izquierda o derecha.

## Ángulo vertical

$\text{atan2}(-Y, \sqrt{(X^2+Z^2)})$

Indica subir o bajar la mirada; ejes de imagen con Y hacia abajo.

12 / TIEMPO REAL Y SEGURIDAD DE RESPUESTA

# La latencia se diseña por modo, no por modelo aislado.

Cada modo tiene una ruta con costo distinto. Se procesan los frames recientes y se mide el tiempo extremo a extremo desde capturar hasta reproducir la respuesta.

01

### FIND MY OBJECT · DETECCIÓN

Detector ligero sobre video reciente → bip apenas se confirma la coincidencia. La profundidad y la descripción llegan después. Si la mochila sale de imagen, seguimos buscando.

CRÍTICA

02

### DISTANCIA · PROFUNDIDAD

Estéreo SGBM + SpatialDepth-Lite + calibración. Se agregan píxeles del objeto (idealmente máscara) y solo se anuncian metros cuando hay validez y confianza suficientes.

RÁPIDA

03

### DESCRIBIR · VLM

Se congela un frame representativo y se consulta el modelo visión-lenguaje. Es más costoso, pero se ejecuta a pedido; se prioriza un resumen breve sin inventar medidas.

A PEDIDO

04

### TEXT READER · OCR

El usuario apunta al cartel y pide «Leé». La imagen se estabiliza o recaptura, se detecta texto, se reconoce en español y se transforma en audio TTS. Si está borroso, se pide reencuadrar.

A PEDIDO

### MEDICIONES PARA DEFENDER LA DEMO

FPS de captura, detección y profundidad; latencia captura→bip y captura→voz; medianas y P95; frames descartados y aciertos de OCR. No prometemos FPS ni milisegundos medidos antes de probar la notebook y el Wi-Fi.

13 / PLAN REALISTA POR ETAPAS

# Primero demostrar el software; después montar el wearable.

Cada hito termina con una evidencia que permite avanzar. Entrenamiento neuronal, experiencia de usuario y montaje físico se validan separadamente antes de integrarse.

01

### ELP USB DIRECTA · ETAPA A

Captura UVC lado a lado, separación de vistas, formato, timestamps y FPS reales.

**Evidencia:** Pares de video estables.

02

### CALIBRAR Y MEDIR

Tablero, intrínsecas y extrínsecas, rectificación, SGBM y distancias de referencia.

**Evidencia:** Error estéreo base documentado.

03

### ENTRENAR SPATIALDEPTH-LITE

GT público, U-Net compacta, incertidumbre, validación externa y ablaciones.

**Evidencia:** Checkpoint + tablas comparativas.

04

### INTEGRAR LOS CUATRO MODOS

Find My Object, distancia, describir y Text Reader (OCR + TTS); prioridad de bip.

**Evidencia:** Demo completa de escritorio.

05

### WEARABLE · ETAPA B

ELP en armazón por USB a Pi 5; alimentación, Wi-Fi y audio. Sin IMU ni CSI.

**Evidencia:** Misma demo sin cable a la PC.

06

### PROBAR Y PRESENTAR

Precisión, confianza, iluminación, OCR, P50/P95 de latencia, fallos y documentación.

**Evidencia:** Experimentos, póster y defensa.

14 / QUÉ QUEREMOS DEMOSTRAR

# Una propuesta útil con un núcleo neuronal medible.

VisionX convierte video estéreo en asistencia auditiva mediante cuatro modos. El aporte investigable es nuestra CNN de profundidad, no una simple conexión entre servicios.

## HIPÓTESIS DE INVESTIGACIÓN

Una CNN compacta puede refinar el mapa estéreo de SGBM, preservar mejor bordes y anticipar qué mediciones son poco confiables, sin impedir una búsqueda interactiva. **Es una hipótesis por validar**, no un resultado previo.

## EVIDENCIAS Y PRUEBAS DE ACEPTACIÓN

| | |
|---|---|
| **Red propia ·** | GT, EPE/MAE/RMSE, incertidumbre y ablaciones frente a SGBM. |
| **Modo buscar ·** | Bip, ubicación visible y reinicio de búsqueda al perder el objetivo. |
| **Distancia ·** | Metros estimados + posibilidad de abstenerse por poca confianza. |
| **Descripción ·** | Respuesta por VLM activada solo cuando se pide. |
| **Text Reader ·** | Texto impreso visible → OCR en español → lectura audible. |
| **Sistema ·** | FPS, P50/P95 de latencia, diferencias USB local vs Wi-Fi. |

**Entregables:** prototipo USB de PC con cuatro modos; wearable como segunda integración; repositorio, mediciones reproducibles, póster y defensa. Informe académico final: límite de 8 páginas.

## FUENTES Y DOCUMENTACIÓN TÉCNICA · ENLACES ACTIVOS


01 OMS · deterioro visual
02 ELP H120 · JX-F35, USB 2.0 UVC
03 Raspberry Pi 5 · especificaciones
04 InStereo2K · imágenes + GT
05 Middlebury · datos estéreo
06 ETH3D · datasets y benchmark
07 FoundationStereo · teacher opcional
08 PaddleOCR · OCR multilingüe