VISIONX

Revisión técnica independiente y alternativas para el plan de trabajo

Evaluación científica, arquitectura neuronal, comparación con trabajos recientes, incertidumbre, datasets, tiempo real, implementación paralela y defensa académica.

Destinatario: Claude, como revisor técnico y coautor del artifact de planificación.
Este documento no ordena incorporar cambios automáticamente. Presenta hipótesis, evidencia verificable, trade-offs, experimentos decisorios y propuestas para discusión crítica entre revisores.

Documento autónomo para intercambio entre sistemas de IA

Basado en “Plan VisionX” (31 pp., exportado 28/10/2026), en “Trabajo Práctico Final” de I308 y en fuentes externas contrastadas hasta 28/10/2026.

Edición 1.0 · 28 de octubre de 2026 · Investigación en curso, sin resultados propios inventados

Índice

1. Protocolo de lectura para Claude: qué es este documento 2

2. Visión del proyecto, utilidad y dos horizontes de entrega 2

3. Investigación: cuál es verdaderamente el aporte propio 3

4. Mapa de trabajos relacionados y modelos candidatos 4

5. Geometría, datasets heterogéneos y calibración 5

6. SpatialDepth-Fusion: diseño, alternativas y pérdidas 7

7. Protocolo de métricas desde el primer día 8

8. Dashboard: cuatro mapas en vivo y visualización tridimensional 9

9. Aplicación y modos: especificación contrastable 10

10. Audio, Bluetooth, Wi-Fi y hardware: adelantar el riesgo 11

11. Arquitectura de software para dos personas verdaderamente paralelas 12

12. Cronograma modular, tareas paralelas y gates 13

13. Gates y decisiones con evidencia 15

14. Demostración ideal para el jurado 16

15. Riesgos, integridad científica, privacidad y condiciones de uso 17

16. Agenda de contraste para Claude: decisiones abiertas 17

17. Bibliografía anotada y enlaces verificables 19

Nota final para el intercambio entre asistentes 20

1 Protocolo de lectura para Claude: qué es este documento

Idea a contrastar

No es un nuevo plan definitivo, ni un "prompt de obediencia", ni una crítica que invalide el trabajo previo. Es una **segunda revisión independiente** para construir una versión mejor del artifact. Contrastar cada sugerencia con las restricciones reales, fuentes, recursos y criterios de evaluación. Mantener trazabilidad de qué se incorpora, descarta o deja abierto.

1.1 Convenciones de evidencia

BASE Descripción constatada en *Plan VisionX*, páginas señaladas, fuente local [S1]. Puede estar equivocada; no es validación externa.

OFICIAL Requisito leído en el TPF o dato documentado por fabricante / paper / repositorio. Incluye enlace verificable [S2,Rxx].

HIPÓTESIS Propuesta razonable no validada empíricamente por el equipo. Debe tener criterio de aceptación y experimento.

CONDICIONAL Recomendación que depende de un benchmark o decisión todavía pendiente.

NO AFIRMAR Algo que no debe presentarse como resultado: exactitud, latencia propia, seguridad del asistente, superioridad de CNN, etc.

1.2 Objetivo del intercambio

Se propone que Claude devuelva una **matriz de decisiones**, con columnas *mantener / modificar / investigar / posponer*, razón, fuente, experimento, costo, riesgo y efecto sobre el resto del sistema. Se busca revisar, no reemplazar ciegamente, el artifact existente. Puede disentir: se valora el disenso sustentado.

1.3 Fuentes de origen examinadas

- [S1] *Plan VisionX*, PDF de 31 páginas, fechado 28/10/2026. Contiene alcance (p. 2), fundamentos (pp. 3–6), calibración (pp. 7–9), datasets y baselines (pp. 9–10), SpatialDepth-Fusion (pp. 11–12), Lite y evaluación (pp. 13–14), aplicación, voz y modos (pp. 15–27), roadmap (pp. 28–29), informe y bibliografía (pp. 30–31).
- [S2] *Trabajo Práctico Final I308*, versión 26.23.10, documento oficial presente en el proyecto. Requiere aprendizaje profundo con datos reales, informe de hasta ocho páginas, código, datasets y póster. Indica grupos de 3/4 y que los temas propios precisan aprobación del profesor.

Advertencia técnica

El plan afirma que una política de IA "lo prohíbe salvo autorización". La **consigna TPF consultada no exhibe esa cláusula explícita**; puede existir en el programa general u otro documento. Se sugiere *verificar y pedir confirmación por escrito*, no repetir una prohibición no cotejada. Sí está documentada la cuestión del tamaño del grupo y la aprobación de tema propio [S2].

2 Visión del proyecto, utilidad y dos horizontes de entrega

2.1 La propuesta central que conviene preservar

VisionX busca asistir a personas con visión reducida, monocular o nula mediante percepción visual estereoscópica y lenguaje auditivo. No sustituye la visión ni garantiza desplazamiento autónomo: es un **prototipo experimental de consulta, localización y percepción contextual** en entornos controlados. La solución combina geometría estéreo, modelos neuronales y una interfaz por voz y sonidos.

Los cuatro modos principales acordados se conservan: **Find My Object**; **Consultar distancia**; **Describir entorno**; **Text Reader**. La guía direccional se limita al objeto visible. **No se añade IMU**: si se pierde el objeto, el controlador suspende

guía y vuelve a buscar. La alerta de proximidad, el wearable y las funciones de memoria o SLAM pueden evolucionar separadamente [S1, pp. 2, 16, 22–27].

2.2 Beta académica vs producto en evolución

	Horizonte A: beta evaluable	Horizonte B: investigación y producto posterior
Hardware	ELP por USB directo a notebook; calibración validada	ELP sobre anteojos, Raspberry Pi 5 y batería al pecho, Wi-Fi y auriculares
Neuronal	Fusion supervisada, incertidumbre y ablations	Lite destilada, teachers adicionales, adaptación de dominio, quizá nuevas arquitecturas
Aplicación	Cuatro modos con flujo auditivo consistente	Alerta robusta, personalización de objetos, memorias, SLAM, guiado fino
Evaluación	Benchmarks, test ELP, latencia y demostración estable	Generalización, usabilidad y experimentos extendidos

No se recomienda *bajar el techo científico* porque la entrega tenga fecha. Sí crear **gates** de resultado: una beta completa puede convivir con tareas ambiciosas abiertas sin que la integración se rompa.

3 Investigación: cuál es verdaderamente el aporte propio

3.1 La novedad relativa: ya hay literatura híbrida

El núcleo del artifact es SGBM + predicción monocular Depth Anything V2 + una U-Net residual de fusión e incertidumbre [S1, pp. 11–12]. Es viable conceptualmente, pero la literatura ya cuenta con enfoques profundos que combinan lo monocular y lo estéreo. En particular:

- **MonSter** (CVPR 2025) integra dos ramas, usa pistas monoculares para zonas difíciles y confianza estéreo para recuperar escala; la interacción es iterativa [R03].
- **DEFOM-Stereo** (CVPR 2025) usa features de un depth foundation model para mejorar encoders de matching, inicialización de disparidad y módulos de actualización de escala [R04].
- **FoundationStereo** (CVPR 2025) busca generalización zero-shot, con datos sintéticos diversos, side-tuning de priors monoculares y filtrado de costos [R05].
- **Fast-FoundationStereo** (CVPR 2026) utiliza destilación, búsqueda de arquitectura por bloques y poda estructurada para mejorar tiempo real sin perder gran parte de precisión zero-shot [R06,R07].

Por eso la hipótesis científicamente defendible no es “somos los primeros en fusionar mapas”. Una formulación candidata es: *“¿Puede una CNN residual compacta de fusión, guiada por confianza, mejorar la exactitud y confiabilidad métrica en interiores con cámara USB de bajo costo, frente a reglas fijas y métodos modernos, con latencia compatible con un asistente interactivo?”*

3.2 Tres preguntas formales

1. **RQ1: Aporte de fusión**. ¿La CNN mejora el error (global y en zonas difíciles) respecto a SGBM+WLS, monocular alineado y regla fija sin aprendizaje? ¿Con qué dispersión por escena?
2. **RQ2: Incertidumbre utilizable**. ¿Su salida probabilística identifica y permite abstenerse de medidas erradas mejor que chequeos geométricos? ¿Cuánto error se ahorra a qué costo de cobertura?
3. **RQ3: Eficiencia y generalización**. ¿El beneficio se conserva con ELP real, compresión MJPEG, diferentes escenas y límites de latencia? ¿Conviene destilar o ejecutar Fusion/otro estéreo neuronal?

3.3 Ablaciones que realmente atribuyen causalidad

La propuesta pide comparar sin Depth Anything, sin indicadores clásicos y sin incertidumbre; se sugiere ampliar con controles de alineación y normalización.

Experimento	Qué se quita/cambia	Qué decide
A0	B4: regla fija, sin red	Ganancia atribuible a aprendizaje
A1	CNN sin canal monocular	Si agrega información distinta de SGBM
A2	CNN sin RGB/bordes	Dependencia del contexto visual
A3	CNN sin máscaras LR/fotométrica	Valor de la confiabilidad clásica
A4	CNN con pérdida SmoothL1 vs NLL	Compromiso error vs incertidumbre
A5	Mono relativo alineado vs métrico	Qué preentrenado conviene en interiores
A6	Corrección residual sin gate vs con gate	Si contener la corrección ayuda a generalización
A7	Aumentos ELP on/off	Robustez a compresión y movimiento
A8	Fusion vs Lite sin/ con distilación	Valor real de la segunda etapa

4 Mapa de trabajos relacionados y modelos candidatos

4.1 Tabla de lectura y uso experimental

Paper/modelo	Qué propone	Aplicación en VisionX	Cautela / pregunta
SGBM / Hirschmüller (2008) [R01]	Matching semiglobal; disparidad desde el par rectificado	Base B0, entradas geométricas, control LR	No es red preentrenada; depende de textura y calibración
Depth Anything V2 (2024) [R02]	Profundidad monocular robusta, versiones relativa y métrica	Canal monocular de Fusion y baseline	Relativa no entrega metros sin alineación; métrica puede sufrir shift
MonSter (2025) [R03]	Fusión iterativa de ramas mono/estéreo	Prior art, baseline avanzado, ideas de confianza	Fusión ya fue investigada; evitar afirmar originalidad absoluta
DEFOM-Stereo (2025) [R04]	Features foundation + matching recurrente, ajuste de escala	Prior art y comparador o teacher	Requiere CUDA/GPU según repo; no copiar complejidad sin hipótesis
FoundationStereo (2025) [R05]	Generalización estéreo zero-shot con priors monoculares	Teacher offline o cota competitiva	Costos de VRAM e instalación; no target automático
Fast-FoundationStereo (2026) [R06,R07]	Destilación + NAS + poda, tiempo real	Rival moderno obligatorio si el entorno permite; teacher alternativo	Tiempos publicados solo inferencia y hardware específico
RAFT-Stereo (2021) [R08]	Optimización recurrente de disparidad	Base profunda clásica comparativa	No es necesario entrenarlo; benchmark reproducible
RecResNet (2018) [R09]	Mejora residual recurrente de disparidad	Antecedente cercano a CNN de refinamiento	No presentar residual refinement como técnica nueva
Poggi et al. (2022) [R10]	Evaluación cuantitativa de confianza estéreo	Métricas y baselines de incertidumbre	La confianza de matching no es seguridad garantizada
Kendall–Gal (2017) [R11]	Modelado de incertidumbre de predicción	Base de NLL y abstención	Interpretación de escala y calibración requieren test
Booster (2022) [R17]	Escenas reales difíciles con brillo/transparencia	Test de casos problemáticos	No prometer GT usable en todo punto sin máscara

4.2 Cifras del modelo reciente que motivó la conversación

El repositorio oficial de **Fast-FoundationStereo** reporta los siguientes tiempos sobre **RTX 3090**, **640 × 480**, para distintos checkpoints/iteraciones, a octubre de 2026 [R07]:

Checkpoint / iteraciones	PyTorch	TensorRT	Memoria pico declarada
23-36-37 / 8	49.4 ms	23.4 ms	653 MB
20-26-39 / 4	37.5 ms	16.4 ms	651 MB
20-30-48 / 4	29.3 ms	14.0 ms	646 MB

Interpretación: dato de un repositorio en condiciones acotadas; no es una tasa de VisionX. No incluye cámara USB, decodificación MJPEG, rectificación, detector, Depth Anything, fusión, VLM/OCR, audio, Wi-Fi ni coordinación de tareas. No extrapolar esos tiempos a Apple MPS ni a la Raspberry. Investigar licencia de checkpoints y restricciones de modelos de NVIDIA antes de incorporar pesos a una distribución pública.

4.3 ¿Usar modelos avanzados como ENTRADA, BASELINE o TEACHER?

Opción	Valor	Riesgo	Prueba decisoria
Salida de DA-V2 como canal Fusion	Complementariedad física y semántica	Dependencia de alineación/latencia	Ablación A1, calidad por zona
Salida de MonSter/DEFOM como canal extra	Ensamble potencialmente más preciso	Modelo ya fusiona; redundancia, teacher leakage y coste alto	Delta error vs mismo modelo solo; latencia total
FoundationStereo teacher offline	Pseudoetiquetas en video ELP	Reproduce sesgo teacher, licencias, complejidad	Student vs GT propio y test independiente
Fast-FoundationStereo baseline/teacher	Referencia fuerte de calidad y tiempo	Puede superar Fusion; dependencias CUDA	Benchmark con mismos frames, mismo GT y resolución
Ensemble de varios estéreo	Mayor robustez en algunos casos	Muchos ms y señales correlacionadas	Complementariedad de errores y Pareto tiempo-error

Idea a contrastar

Probar una arquitectura "stack de muchos modelos" es válido como **investigación**, pero no basta con agregar entradas: cuando las fuentes están fuertemente correlacionadas, la CNN puede no ganar nada. El valor se demuestra con ablaciones y frente a un baseline de ensamble sin aprendizaje. Diferenciar claramente *teacher para entrenamiento* de *dependencia de inferencia*.

5 Geometría, datasets heterogéneos y calibración

5.1 La física y el cambio de cámaras

En estéreo rectificado ideal, $d = fB/Z$ y $Z = fB/d$. El plan muestra un baseline nominal cercano a 59 mm obtenido en el TP2 [S1, pp. 3–5]; no asumirlo como medida validada de la unidad física definitiva. Una cámara de gran angular puede exigir un modelo de distorsión distinto. Repetir calibración y validar por geometría real.

La pérdida de precisión de profundidad con la distancia es aproximadamente $|\partial Z/\partial d| = fB/d^2 = Z^2/(fB)$; por eso un error subpíxel importa mucho a tres metros. **Reconocer objetos más allá de 3 m no implica poder dar metros fiables.** Evaluar coberturas por rango y no imponer el límite de 3 m a toda detección.

5.2 Corrección relevante sobre normalización de disparidad

El plan sugiere dividir disparidades por el parámetro SGBM `numDisparities` [S1, p. 10]. Ese parámetro es la *ventana de búsqueda*, no una representación invariante de cámara. Propuesta a evaluar: un adaptador geométrico común por dataset, con metadatos de K_1, K_2, R, T, Q, escala de imagen, offset de centro principal y convención de signo.

Cuando la rectificación alinea centros principales, $q = d/(fB)$ es una candidata a profundidad inversa; si existe un offset, debe contemplarse. Middlebury publica explícitamente

$$Z[\text{mm}] = \frac{f[\text{px}]\, B[\text{mm}]}{d[\text{px}] + \texttt{doffs}[\text{px}]},$$

con `doffs` definido en su archivo `calib.txt` [R15]. Si el pipeline usa $Q = \texttt{stereoRectify}(\cdots)$ puede reproyectar con `reprojectImageTo3D`, teniendo en cuenta la escala SGBM (valores enteros de precisión $1/16$) [R16].

Advertencia técnica

No mezclar directamente disparidades y predicciones monoculares procedentes de cámaras distintas como si todas expresaran metros. Para datasets sin calibración suficientemente confiable, separar el experimento de disparidad nativa del experimento métrico, o utilizar priors relativos con alineación robusta. Nunca inventar calibraciones faltantes.

5.3 Protocolo de calibración revisado

El plan propone ChArUco, múltiples sesiones y validación independiente [S1, pp. 7–9]; se recomienda conservarlo con estas modificaciones opcionales:

1. Capturar tablero a distintas orientaciones, rangos y posiciones en ambos sensores, con foco y resolución fijados. Medir tamaño real de casillas y planitud del soporte.
2. Comparar calibración *pinhole radial-tangencial* vs *fisheye/omnidireccional* si la cobertura angular y residuos lo justifican. Evaluar error de rectificación y sesgo métrico en los bordes, no solo RMS interno.
3. Validación estratificada: centro, laterales, cercanía, distancia, tablero parcialmente visible; capturas no usadas para calibrar.
4. Validación física adicional: cinta o láser independiente, con referencia axial definida respecto al plano de la cámara, no solamente solvePnP derivado de la misma K.
5. Guardar versión de cámara, serial, modo USB, resolución, foco, timestamps, K, D, R, T, P_1, P_2, Q, unidades y fecha en YAML/JSON. Hash de la calibración en todos los logs.

5.4 Registro de los datasets

Dataset y fuente	Uso previsto	Cuidados
InStereo2K [R13]	Entrenamiento principal supervisado; 2000 train / 50 test, imágenes interiores	PNG disparidad 16 bit / 100; ceros inválidos; revisar licencias y partición por escena
Middlebury 2014 [R15]	Evaluación externa de alta calidad y casos variados	Manejar doffs y GT públicos solo para split de entrenamiento; test oficial no siempre tiene GT descargable
ETH3D [R14]	Evaluación externa y generalización	Dos vistas con GT de escáner láser; algunos píxeles sin GT; formatos variables
Booster [R17]	Casos difíciles: vidrio, brillo, transparencia	Material masks, disparidad válida; alta resolución demanda recortes
Scene Flow [R18]	Preentrenamiento o regularización si falta diversidad	Dominio sintético; riesgo sim-to-real; no reemplaza test real
ELP etiquetado acotado [S1]	Verificación de metros por objeto y tableros	Distancias independientes y escenas no usadas para adaptar
ELP sin etiquetas	Adaptación opcional y pseudo-labels teacher	Recolectar diversidad, excluir escenas test; frames vecinos no son muestras independientes

5.5 Datasets adicionales para investigación, no adopción automática

Investigar **CREStereo** / datasets reales de matching, **KITTI 2012/2015** para dominio exterior, **Sintel Stereo** para consistencia temporal y **datasets de RGB-D de interiores** (p. ej. NYU Depth V2) como referencias monoculares, siempre revisando si proveen *pares estéreo, calibraciones y GT* para la tarea concreta. NYU Depth V2 es RGB-D y no debe presentarse como equivalente directo a InStereo2K. Consultar licencias, splits, formato, convención de disparidad y dominio antes de expandir.

5.6 Particiones y ausencia de fuga

- Separar por **escena/sesión/habitación**, no por frames consecutivos. Bloquear un test final por cámara y entorno. No sintonizar sobre test público repetidamente.
- Guardar `dataset_version`, hashes, split manifests y scripts de preprocesamiento. Versionar normalización y fuentes de pseudo-labels.
- Al aplicar escalado/crop, transformar K, disparidad, profundidad y máscaras de forma coherente. No hacer flip horizontal indiscriminado sin permutar cámaras y signos.
- Comparar sin / con augmentations que emulen MJPEG, diferencias fotométricas entre ojos, blur, clipping, baja luz, oclusión y cambios de escala. Evitar manipulación geométrica que viole la epipolaridad.

6 SpatialDepth-Fusion: diseño, alternativas y pérdidas

6.1 Entradas y salidas del artifact

El artifact propone 10 canales: RGB(3), disparidad SGBM, máscara de validez, desacuerdo LR, error fotométrico, bordes, monocular alineado y diferencia de fuentes [S1, pp. 11–12]. U-Net de cuatro niveles con 32/64/128/256 features, aproximadamente dos millones de parámetros *como estimación del plan, no cálculo verificado*. Cabezas: corrección residual y escala de incertidumbre.

6.2 Tres candidatos arquitectónicos realmente comparables

F0: Residual simple
$d_f = d_0 + \Delta d$. Inicializar última capa en cero para que inicialmente iguale baseline. *No garantiza que después del entrenamiento no empeore.*

F1: Residual con gate
$d_f = d_0 + g(I, C)\Delta d$, $0 \leq g \leq 1$. Permite controlar magnitud de corrección, sin garantía automática de mejora; medir en test.

F2: Expert gating
$d_f = w_s d_s + w_m d_m + \Delta d$, con pesos espaciales aprendidos y máscaras explícitas de fuentes válidas. Mayor interpretabilidad potencial, pero puede colapsar o aprender shortcuts; control con B4.

No convertir F2 en obligación: el criterio científico es identificar la *menor complejidad que añade valor* a igualdad de datos y protocolo.

6.3 Profundidad monocular: relativa vs métrica

Relativa: la salida requiere alineación de escala y posiblemente shift. El plan sugiere ajustar $d_s \simeq s\, m + t$ con RANSAC en regiones confiables [S1, pp. 4–5, 11]. Investigar si la salida m debe invertirse o transformarse antes según convención del checkpoint; verificar numéricamente que aumente con cercanía. Almacenar `align_quality`, residuos, cantidad/dispersion de inliers, y bandera de fallo.

Métrica Indoor: Depth Anything V2 ofrece variantes entrenadas para predecir metros (Hypersim/indoor). La versión Small tiene aproximadamente 24.8M parámetros [R02,R12]. Convertir Z_m a disparidad mediante la calibración y respetar unidades/rangos. Incluir como baseline independiente y variante de entrada, no asumir que supera la relativa alineada.

6.4 Pérdida principal e incertidumbre

Una Laplace NLL parametrizada en escala positiva b_p propone:

$$\mathcal{L}_{\text{NLL}} = \frac{1}{|\Omega|} \sum_{p \in \Omega} \left(\frac{|d_f(p) - d_{GT}(p)|}{b(p)} + \log(2b(p)) \right), \qquad b = \text{softplus}(a) + \varepsilon.$$

El término $\log(2b)$ incluye la constante de normalización, irrelevante al gradiente de b salvo constantes; definir dominio y clamp numérico. Investigar combinar NLL con **SmoothL1, loss de bordes, consistencia fotométrica con oclusiones enmascaradas y métrica de distancia**, evitando una función final con demasiados pesos que no puedan ablacionar.

En caso de GT métrico, medir también $|Z_f - Z_{GT}|$ o relativo en distancias de interés. Evitar convertir cada gradiente de disparidad en metros sin máscara y sin limitar zonas de profundidad extrema.

6.5 Qué significa “incertidumbre baja”

Advertencia técnica

La meta **NO** es minimizar b indiscriminadamente. Un modelo que siempre predice confianza alta y se equivoca sería peligroso. La meta es **calibración**: incertidumbre alta donde el error tiende a ser alto, intervalos que contienen las profundidades reales en la frecuencia prevista y un buen balance entre cobertura y error selectivo.

6.6 Destilación a Lite: planteo condicional

Una ruta posible: teacher Fusion (o FoundationStereo/Fast-FoundationStereo) offline produce pseudo-labels filtrados en video ELP; student Lite aprende con GT real + pseudo-etiquetas en sesiones distintas. La pérdida podría ser:

$$\mathcal{L}_{Lite} = \lambda_{GT}\mathcal{L}_{\text{sup}} + \lambda_T \mathbb{1}[\text{teacher_ok}]\,\rho(d_L - d_T) + \lambda_C \mathcal{L}_{\text{consistencia}}.$$

Comparar (i) Lite supervisada sola, (ii) Lite con pseudo-labels, (iii) Fusion y (iv) teacher grande. No asumir que un teacher necesariamente transfiere buena calibración de incertidumbre; realizar calibración del student por separado.

Idea a contrastar

La decisión de entrenar Lite **debería depender de un benchmark**. Si Fusion y DA-V2 en la GPU de demo ya satisfacen latencia con margen, la destilación puede convertirse en experimento opcional de investigación, no condición para tener un producto. Si no satisfacen, Lite gana prioridad.

7 Protocolo de métricas desde el primer día

7.1 Separar four dimensiones: precisión, confianza, tiempo y utilidad

Medida	Fórmula / definición	Interpretación y prueba
EPE disparidad	$\text{mean}_\Omega \lvert d_f - d_{GT}\rvert$	Menor es mejor; acompañar con mediana, P90, intervalos por escena
bad-1 / bad-2	% píxeles válidos con error $>1, >2$ px	Menor es mejor; definir exactamente el umbral por benchmark
MAE / RMSE en Z	mean$\lvert Z_f - Z_{GT}\rvert$, raíz del MSE	Medida directamente relevante para usuario; estratificar por 0.5–1, 1–2, 2–3 m
Error relativo	$\lvert Z_f - Z_{GT}\rvert / Z_{GT}$	Comparación proporcional por distancia; excluir $Z_{GT} \approx 0$
Tasa válida	$\lvert\Omega_{pred} \cap \Omega_{GT}\rvert / \lvert\Omega_{GT}\rvert$	Un método no debe “ganar” eliminando todos los píxeles difíciles
AUSE / sparsification	Error tras eliminar mayores b vs curva oráculo	Menor AUSE mejora ranking de errores; no implica calibración probabilística
Cobertura-error	MAE entre predicciones aceptadas a x % cobertura	Cuánto mejora al abstenerse; reportar error y % de casos sin respuesta
Cobertura de intervalos	% Z_{GT} dentro de intervalo nominal	Calibración; medir por rango y dominio. Enlace entre b_d y b_Z no es lineal
NLL	Log-verosimilitud de d_{GT} bajo predicción	Penaliza overconfidence y exceso de incertidumbre; comparar en split externo
Latencia P50/P95/P99	Delta captura–evento–audio	Medir distribución, no solo FPS medio; objetivos específicos por modo
FPS efectivo + edad del frame	Frames inferidos/s; now–timestamp usado	Mapas visualmente fluidos no garantizan información actual
Find: tasa de éxito/falsos bips	Objetivo correcto, falsos por minuto	Separar clases COCO y open-vocabulary; test con objetivo ausente
Distancia: éxito de respuesta	Respuestas correctas a tolerancia y abstenciones	Medir objetos con GT independiente, máscara y oclusiones
Describe: groundedness	Afirmaciones apoyadas en la imagen; alucinaciones	Evaluación humana con protocolo y muestras etiquetadas
Text Reader: CER / WER	Distancia de edición normalizada	Evaluar números, signos, líneas y ruido, no solo lectura fluida
Audio: order success / first-audio	Órdenes interpretadas y latencia voz–respuesta	Ruido, distintas voces, Bluetooth y reconexiones

7.2 Experimentos de incertidumbre paso a paso

1. Validación con GT: calcular $e_p = \lvert d_f - d_{GT}\rvert$, b_p, residuo normalizado y rangos por píxel.
2. **Ranking**: ordenar por b_p creciente; para coberturas 50, 60, 70, 80, 90, 95, 100 %, medir EPE/MAE de los aceptados; compararlo con orden por e_p (oráculo) y con LR consistency/fotométrico.
3. **Calibración**: para un modelo Laplace, verificar cobertura de intervalos $\hat{d} \pm b\log(1/(1-\alpha))$ para confianza α bajo la parametrización usada. En metros transformar extremos de disparidad monotónicamente y gestionar cambios de signo, cero y restricciones.

4. **Por objeto**: agregar incertidumbre con estadística robusta dentro de máscara, fracción de píxeles válidos y dispersión espacial. Calibrar umbral de abstención *por objeto*, no transplantar umbral por píxel.
5. **Desplazamiento de dominio**: repetir en ELP, compresión, baja luz, bordes, oclusiones, superficies brillantes y zonas planas; reportar dónde falla la confianza.

7.3 Grupos de evaluación obligatorios

En cada modelo, al menos: **global**; **bordes**; **oclusiones**; **baja textura**; **superficies reflectantes**; **por distancia**; **según posición radial en la cámara**; **según compresión y movimiento**. Los criterios de segmentación de esas zonas deben documentarse (GT/máscaras, gradiente o anotaciones), no seleccionarse después para favorecer Fusion.

7.4 Baselines justos y reproducibles

B0 SGBM; B1 SGBM postprocesado; B2 SGBM+WLS; B3 Depth Anything relativo alineado; B4 combinación fija SGBM/mono; B5 Depth Anything Metric Indoor; B6 Fusion; B7 Lite (si existe); U1 FoundationStereo; U2 Fast-FoundationStereo; U3 MonSter/DEFOM (si factible). No comparar números de papers tomados de benchmarks distintos: ejecutar **todos sobre el mismo split, resolución, formato, máscaras, hardware y protocolo**.

El GPU benchmark debe separar *latencia módulo* y *latencia completa de cámara a audio*. Cuantificar precalculado offline vs cómputo online: no cobrarle a Fusion el costo de DA-V2 dos veces, pero tampoco ocultarlo.

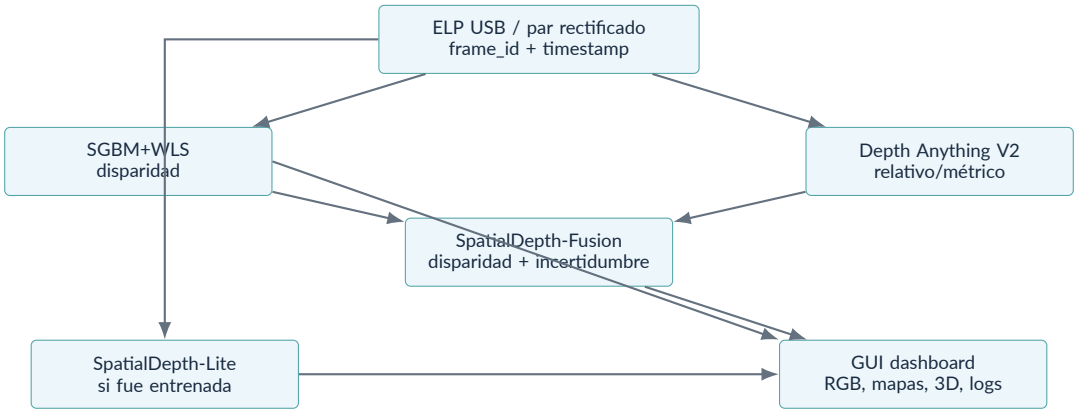
7.5 Criterios de éxito propuestos, NO resultados garantizados

- Primario: disminuir EPE/bad-2 frente al *mejor baseline híbrido sin aprendizaje*, en test independiente y con diferencia consistente entre escenas.
- Complementario: mejorar cobertura-error/AUSE respecto a incertidumbre clásica y calibrar intervalos. Una mejora de error sin calibración no alcanza para afirmar confiabilidad.
- Aplicación: distancias objetuales dentro de tolerancias predeclaradas para 0.5–3 m, con abstención razonable; comparar con y sin Fusion.
- Interacción: p95 de captura a bip / comando a primera palabra bajo umbrales predefinidos *tras benchmark real*. Los presupuestos de latencia son objetivos de ingeniería, no características del hardware garantizadas.
- Presentar siempre **dos o más casos donde Fusion empeora** y explicar límites, con el mismo criterio de transparencia que los éxitos.

8 Dashboard: cuatro mapas en vivo y visualización tridimensional

8.1 Viabilidad y propuesta de interfaz

Sí, se puede mostrar simultáneamente RGB rectificado, SGBM, Depth Anything, Fusion y Lite. Pero *cuatro mapas visibles* no obligan a *cuatro modelos evaluados al mismo FPS*. Un dashboard experimental puede usar tasas y timestamps independientes, mostrar edad de cada resultado y un toggle “sincronizar por frame” para comparación científica.



8.2 Paneles concretos

1. **Video RGB + detección**: imagen izquierda rectificada, segmentaciones, ID de seguimiento, objeto seleccionado, ángulos y distancia.
2. **SGBM**: mapa de disparidad crudo y corregido, máscara de invalidez y confidencia LR.
3. **Depth Anything V2**: mapa original relativo/métrico (etiqueta visible), versión alineada a la calibración, calidad de alineación.
4. **Fusion**: mapa de profundidad en metros, incertidumbre (b_d, conversión a metros/intervalo cuando corresponda), zonas de abstención.
5. **Lite**: si existe, mapa con edad y tiempo de inferencia; comparación visual con Fusion.
6. **Panel cuantitativo**: frame ID, FPS captura, FPS detector, tiempos por modelo, VRAM, retraso de cámara a pantalla, edad del último resultado, conexión/audio.
7. **3D point cloud**: usar Q y mapa de disparidad válido para nube de puntos en marco de la cámara. Colorear por RGB, filtrar outliers y permitir rotación/zoom. NO denominarlo mapa 3D persistente.
8. **Benchmark con GT**: cuando se carga una escena etiquetada, incorporar panel de error, tabla, histogramas, curvas por zona y comparación lado a lado en la misma escala de color.

8.3 Precaución geométrica con reconstrucción en movimiento

Cada frame produce una nube de puntos 3D en el sistema de la *cámara actual*. Si se mueve la cámara sin visual odometry, la nube no queda alineada con la nube anterior. Un **mapa de profundidad vivo o una reconstrucción por frame** sí entra en el alcance. **Acumular una escena 3D persistente** requiere estimar pose (SfM/SLAM) y queda como extensión. Se puede mostrar el point cloud de cada instante sin almacenar trayectoria.

8.4 Arquitectura de ejecución de la GUI

Un servicio de captura produce `StereoFrame`; procesadores consumen el frame más reciente; salidas identificadas por `frame_id`; GUI muestra estado y timestamps. Ofrecer dos modos de visualización:

- **Live**: prioriza actualidad y experiencia. Un modelo lento no bloquea YOLO ni el bip; se acepta que mapas en pantalla tengan edades distintas con etiquetas.
- **Bench/replay**: procesa el mismo frame guardado por todos los métodos, espera a completar y presenta resultado sin confundir el usuario con tiempos diferentes. Permite exportar video, tablas y figuras reproducibles.

9 Aplicación y modos: especificación contrastable

9.1 Máquina de estados y política de prioridades

Mantener un controlador determinista: `Idle`, `Searching`, `Choosing`, `Guiding`, `Distance`, `Describe`, `Read`; eventos `Cancel`, `Repeat`, `TargetLost`, `Reconnect`. Un comando nuevo puede cancelar un trabajo pesado pendiente; cada resultado lleva `request_id` para que la respuesta tardía de un VLM no interrumpa otro modo.

Modo	Activa	Qué devolver y cuándo rechazar
Buscar	Detector rápido + seguimiento y 3/5 detecciones	Bip primero, distancia después si confiable; objetivo ausente y múltiples instancias
Guiar (submodo)	Objeto actualmente visible y asociado a ID	Izquierda/derecha/arriba/abajo; si se pierde, detener y volver a Buscar
Distancia	Frame reciente + detector/segmentación + Fusion	Metros o rango + confianza; si fuera de rango o baja cobertura, abstenerse
Describir	Frame congelado + VLM + hechos geométricos	Frases cortas, hechos y estimaciones separados; no inventar medidas
Leer	Imagen alta resolución + OCR y TTS	Texto fiel, pedir nuevo encuadre si baja confianza; partes opcionales

9.2 La pérdida del objeto: caso que hay que ensayar

Secuencia propuesta: `Searching` → `Found` → `Guiding`. En cada frame comprobar presencia y coherencia de instancia. Si el objetivo sale de imagen o la confianza cae, aplicar histéresis breve (por ejemplo 0.5–2 s *a medir*), apagar audio de guía, anunciar "lo perdí de vista, seguí buscando" y volver a

`Searching`. Si aparece un objeto igual: confirmar identidad si el tracker no puede desambiguar. Sin IMU no calcular una dirección absoluta del objetivo fuera de cuadro.

Test específico: usuario gira intencionalmente al lado contrario; medir demora para detectar pérdida, instrucciones incorrectas emitidas tras pérdida, tiempo de reacquisición, falsos bips, ID-switches con dos objetos iguales.

9.3 Distancia de un objeto: qué distancia se enuncia

No usar medianas de cajas completas salvo fallback etiquetado. Definir por experimento qué se comunica: superficie visible típica (mediana robusta), superficie visible cercana (percentil bajo filtrado) o posición de un punto de referencia. Documentar elección. Medir GT para ese mismo significado: objeto extenso no tiene un único Z. Evaluar cobertura de máscara, textura, errores en bordes, oclusiones y la distancia euclídea vs profundidad axial Z.

9.4 VLM/OCR/voz: dependencias no críticas

Detección y bip no deben bloquearse por OCR, VLM ni voz larga. Un VLM por API puede explicar contexto, pero no debe calcular metros "a ojo". La salida se valida contra objeto, distancia y timestamp del motor geométrico. OCR prioriza exactitud literal, con prueba de números y precios; TTS sintetiza en cola única con prioridades y cancelación.

9.5 Tres capacidades invisibles de alta rentabilidad

1. **Diagnóstico de arranque**: par estéreo válido, parámetros de cámara, hash calibración, fps, modelos disponibles, red, botón, micrófono, auriculares y energía de Pi.
2. **Edad de dato**: todo evento con `frame_id`, `capture_ts`, `inference_ts`, `audio_ts`; rechazar guía basada en frames excesivamente viejos.
3. **Motor único de confianza**: combina detección, validez geométrica, incertidumbre calibrada, edad y consistencia temporal para decidir `SpeakMeters`, `SpeakDirectionOnly`, `AskReframe`, `Abstain`.

10 Audio, Bluetooth, Wi-Fi y hardware: adelantar el riesgo

10.1 Por qué adelantar Bluetooth a la primera semana

La aplicación final contempla AirPods Bluetooth y Raspberry en el pecho. **Bluetooth A2DP** está orientado a reproducción de alta calidad y **HFP/HSP** a micrófono bidireccional; el cambio de perfil puede afectar muestreo, canal, latencia y compatibilidad. Según OS/pila de audio, no siempre se consigue simultáneamente el comportamiento previsto. La duda se resuelve *probando hardware real*, no esperando a la semana cinco.

- Test 1: Raspberry → AirPods, bip y voz; reconexión y prioridad de audio.
- Test 2: AirPods mic → Raspberry → notebook, con un ciclo de voz y transcripción; registrar formato efectivo, dropout y p95.
- Test 3: hablar mientras reproduce una respuesta: ¿se corta, mezcla, cambia perfil? Prueba con cancelación.
- Fallback: micrófono USB en Raspberry, o micrófono cableado/externo; AirPods solo salida. Se selecciona por resultados, no por estética.

10.2 Cámara real USB: separar puerto de protocolo

La ficha oficial ELP-USB3D1080P02-H120 declara **USB 2.0 High-Speed UVC**, dos sensores JX-F35, par 3840x1080 MJPEG con modos hasta 60 FPS nominales, lente HFOV aprox. 125 grados y rolling shutter [R19]. Conectar a puerto USB 3 no transforma su enlace en USB 3. Medir FPS reales, timestamps entre ojos, exposición, artefactos MJPEG y captura bajo movimiento. Evitar asumir que la etiqueta comercial "USB3D" significa USB 3.0.

10.3 Transporte de video y energía

Para etapa A, USB directo a notebook. Para B, ELP por USB a Pi; Pi reenvía frames con IDs y timestamps, notebook procesa, Pi reproduce audio. Comprobar si la API de captura entrega MJPEG comprimido; con algunas rutas OpenCV se obtiene RGB decodificado, y reenviar "sin recodificar" requiere acceso a buffers MJPEG/V4L2/GStreamer. Preferir *latest-frame + descarte*, no una cola infinita que acumule latencia.

La documentación Raspberry Pi señala que la Pi 5 tiene hasta 1.6 A USB con fuente 5V/5A reconocida y un límite típico de 600 mA con otras fuentes [R20]. La ELP declara 210–240 mA nominales [R19]; evaluar fuente, arranque, temperatura y power bank bajo carga real, no concluir que necesariamente requiera 5 A solo por la cámara.

10.4 Apple Silicon vs NVIDIA vs VMs

Una Mac Pro/Pro-class potente puede utilizar PyTorch MPS/Metal; modelos con custom CUDA, FlashAttention compilada, TensorRT o dependencias CUDA específicas pueden **no correr directamente** en macOS [R21]. Para Fast-FoundationStereo el repo oficial documenta instalación orientada a CUDA/PyTorch NVIDIA [R07]. Considerar:

Equipo	Uso natural	Prueba de compatibilidad
Mac Apple Silicon	Dashboard, prototipado, U-Net PyTorch MPS, VLM compatible	Operadores disponibles, precisión, VRAM unificada, FPS real
Linux + RTX/VM GPU	Fast-FoundationStereo, FoundationStereo, TensorRT y teachers	CUDA, drivers, pesos, cost/time, latencia de transferencia
Raspberry Pi 5 2GB	Captura, red, botón, Bluetooth, audio	UVC, memoria, energía y stream sin recompresión

Si la VM está remota por Internet, usarla **principalmente para entrenamiento y benchmarks offline**. La demostración interactiva debe medir costo de ida y vuelta si decide inferir remotamente.

11 Arquitectura de software para dos personas verdaderamente paralelas

11.1 Principio central: contratos antes que módulos

Una persona no debe esperar a que la otra finalice un modelo. Ambos trabajan contra interfaces estables y fixtures grabados. Propuesta de mensajes versionados:

```
StereoFrame {schema, frame_id, capture_ns, source_id,
  left_rgb, right_rgb, calibration_id, resolution, rectified}
DepthResult {schema, frame_id, model_id, disparity_px,
  depth_m, valid_mask, uncertainty, uncertainty_kind,
  inference_ms, alignment_quality}
DetectionResult {schema, frame_id, boxes, masks,
  classes, scores, track_ids}
SpatialObject {frame_id, track_id, label, angle_h_deg,
  angle_v_deg, z_axial_m, range_m, confidence,
  valid_fraction, distance_policy}
Command {request_id, mode, target, utterance, timestamp}
AudioEvent {request_id, priority, text_or_sound, deadline,
  cancelable, originating_frame_id}
```

Para evitar copias masivas de imágenes, los contratos pueden representar handles, memoria compartida o referencias al frame. La definición semántica de cada campo se mantiene igual entre prototipo y versión definitiva.

11.2 Estructura sugerida de repositorio

```
visionx/
  configs/             # hardware, modelos, umbrales
  docs/                # ADR, interfaces, diagramas, papers
  datasets/            # manifests, no subir datasets pesados a Git
  src/visionx/
    camera/             # usb, replay, rasp_stream
    calibration/        # charuco, stereo, maps
    depth/classical/    # SGBM, LR, WLS, baseline B4
    depth/learned/      # fusion, lite, teachers, losses
    depth/eval/         # epe, bad2, mae, ause
    detection/          # segmentacion, tracking, open vocab
    speech/             # vad, stt, intent, tts
    modes/              # FSM, policies, voice commands
    gui/                # panels, point cloud, logs
    transport/          # zeroMQ, usb, control, audio
    shared/             # schema, timestamps, events
  tests/               # unit, integration, replay, hardware
  experiments/         # yaml config, CSV, plots, model cards
  scripts/             # download, preprocess, benchmark
  .github/workflows/   # tests y lint
```

11.3 Diseño de ramas e integración

- **main protegida**; PR pequeñas por tarea, dos revisiones cruzadas en módulos de interfaz, evitar tocar simultáneamente archivos comunes sin acuerdo.
- Configuraciones `yaml` + pins `requirements/uv.lock` o equivalentes; Mac/CUDA con extras separados, pero esquemas idénticos.
- **ADRs** (Architecture Decision Records): problema, opciones, decisión, evidencia, costo de reversión. Esenciales para justificar TPF y permitir que Claude recomiende cambios sin perder historial.
- Tests con `FakeDepth`, `RecordedFrames`, `FakeAudio`, `FakeDetector`; CI ejecuta una secuencia de punta a punta sin GPU ni hardware.
- Entornos reproducibles: fijar semillas, git SHA, checkpoint SHA, versiones de datasets, calibración, splits y config. Exportar tablas y gráficas mediante scripts.

11.4 Matriz de propiedad y no bloqueo

Área	Persona A, owner inicial	Persona B, owner inicial	Interfaz para integrar
Datasets/GT/splits	A	B audita	`DatasetSample` con calibración
Baselines y métricas	A	B genera casos físicos	`DepthResult`, CSV
Fusion y Lite	A	B valida en ELP	Modelo ONNX/PT + metadata
Captura/calibración ELP	B	A diseña tests	`StereoFrame`, YAML calib
Detector/seguimiento	B	A evalúa distancia por máscara	`DetectionResult`
Controlador de audio/OCR	B	A aporta confianza	`Command`, `AudioEvent`
Dashboard / replay	B (UI)	A (comparación y gráficos)	`FrameResultBundle`
Eval end-to-end	ambos, suites distintas	ambos, suites distintas	Fixtures y scripts con hashes
Wearable/streaming	B	A mide latencia de GPU	Mismo `StereoFrame` en transportes
Informe/póster	ambos por capítulo	revisión cruzada	Tablas y figuras generadas

Idea a contrastar

La división *A=modelos/B=aplicación* es útil como propiedad, pero **no implica dependencia**. A dispone de pares públicos y baseline, B usa fake depth y replay; ambos entregan contra contratos. Cada integración debe funcionar aunque el módulo real del compañero aún no esté listo.

12 Cronograma modular, tareas paralelas y gates

Se propone mantener **horizontes flexibles**: siete semanas como primera beta, no como fecha de muerte del proyecto. Cada tarea tiene ID, owner, dependencia, artefacto y test. Claude puede adaptar fechas y reparto. El equipo debe revisar semanalmente prioridades a partir de métricas, no de entusiasmo.

12.1 Semana / sprint 0: convenio de integración y fuentes

ID	Resp.	Tarea	Entregable / salida verificable
S0-01	A	Descargar/validar InStereo2K y licencias	Manifest con hashes, 10 muestras visualizadas y GT
S0-02	B	Enumerar ELP modos UVC en Mac/Linux	CSV de resoluciones/FPS/formatos y muestras sin separar
S0-03	A	Definir geometría/dtypes y evaluación	Esquema DepthResult, tests matemáticos
S0-04	B	Definir StereoFrame y captura replay	API stub + 20 pares grabados con timestamps
S0-05	A	Papers prioritarios y baseline de reproducción	Tabla versiones/repos, scripts instalables
S0-06	B	Prueba Bluetooth bidireccional temprana	Audio loopback + logs de perfiles/latencia
S0-07	Ambos	Contratos, repo, CI, review, reglas IA/TPF	PR inicial, ADR, consultas a cátedra

12.2 Sprint 1: geometría reproducible y aplicación simulada

ID	Resp.	Tarea	Evidencia y dependencia
S1-01	A	SGBM en InStereo2K y máscaras LR	B0 CSV + mapas + GT, depende S0-01
S1-02	A	B1/B2: filtros y WLS	EPE/bad2/latencia comparativa
S1-03	A	Script de métricas por zona	Unit tests con mapas artificiales
S1-04	B	ChArUco y primera calibración	K/D/R/T/Q + RMS y rectificado
S1-05	B	YOLO/segmentación con replay	Detecciones y masks en interfaz
S1-06	B	FSM básica + fake audio	Buscar/Perder/Cancelar reproducibles
S1-07	Ambos	Integrar SGBM real a dashboard fake	Demo de pared y objeto a distancia medida

12.3 Sprint 2: monocular y comparadores / cuatro modos sin modelos pesados

ID	Resp.	Tarea	Evidencia
S2-01	A	DA-V2 relativo y métrico en sample	Formato, min-max, tiempo, alineación
S2-02	A	B3/B4 reglas de fusión	Error por rango y regiones difíciles
S2-03	A	Fijar split sin fuga y calibración dato	Manifests + tests de conversión
S2-04	B	Recalibración segundo/tercer set	Estabilidad, y-error, GT físico independiente
S2-05	B	Voz/STT/intents y cancelación	50-100 órdenes con errores y latencias
S2-06	B	Text Reader y descripción con mocks	OCR CER en imágenes + modo GUI
S2-07	Ambos	Dashboard de cuatro mapas con mocks	Misma escena y timestamps controlados

12.4 Sprint 3: Fusion y demo de laboratorio

ID	Resp.	Tarea	Evidencia
S3-01	A	U-Net 10 canales + residual + NLL	Entrenamiento, curvas, checkpoint reproducible
S3-02	A	Ablaciones A1/A3 iniciales	Tabla contra B2 y B4, intervalos por escena
S3-03	A	Incertidumbre y reliability scripts	AUSE, error-coverage, calibrated intervals
S3-04	B	Distance+Find con DepthResult real	10 objetos, bip y pérdida correcta
S3-05	B	VLM/OCR/TTS en modo solicitud	p50/p95, cancelación, no medidas inventadas
S3-06	Ambos	Demo de laboratorio end-to-end	Cuatro modos y export video/replay

12.5 Sprint 4: evaluación avanzada, teachers y decisiones

ID	Resp.	Tarea	Evidencia
S4-01	A	Test externo Middlebury/ETH3D	Métricas por escena, sin test leakage
S4-02	A	Fast-FoundationStereo RTX benchmark	FPS/P95/precio VRAM en mismos frames
S4-03	A	Comparación MonSter/DEFOM (si factible)	Cota de calidad y compatibilidad
S4-04	B	Banco de mediciones ELP y errores	MAE objeto, rangos y abstención
S4-05	B	Comportamiento multisujeto y pérdida	ID switches, falsas alarmas/min
S4-06	Ambos	Gate: ¿Fusion necesita Lite?	Decisión con tabla de accuracy vs latency

12.6 Sprint 5: wearable y/o destilación en paralelo

ID	Resp.	Tarea	Evidencia
S5-01	A	Pseudo-labels teacher en video ELP	Quality gate + manifests + muestras
S5-02	A	Lite destilada (si gate lo exige)	Accuracy-latency, test sin mejorar autoengaños
S5-03	A	Perfil GPU en Mac y RTX	VRAM, throughput, p95, compatible stack
S5-04	B	Raspberry USB + MJPEG + Wi-Fi	Drop frames, buffer, jitter, video estable
S5-05	B	Batería, wearable, botón y audio	Autonomía, 30 min temperatura, mic + AirPods
S5-06	Ambos	USB vs Wi-Fi mismo video/replay	Degradación de latencia y FPS, comparación

12.7 Sprint 6: cierre de beta y comunicación

- A: congelar pesos, splits y scripts; producir tablas y visualizaciones con datos no seleccionados a mano.
- B: congelar controlador y GUI; grabar demo con logs de latencia y recuperación de errores.
- Ambos: informe IEEE ($\leq$8 páginas), póster A0/A1 vertical, referencias, repos reproducible, video de respaldo y ensayo de preguntas del jurado [S2].

12.8 Backlog post-beta sin sacrificar investigación

Mayor robustez wearable, Live inference de cuatro fuentes en GPU potente, Lite opcional, alertas de proximidad con pruebas seguras, reconocimiento de objetos personales, memoria, nube de puntos acumulada mediante pose, SLAM y estudio con usuarios. Cada extensión empieza con hipótesis y métricas y no modifica silenciosamente la beta congelada.

13 Gates y decisiones con evidencia

Gate	Condición a comprobar	Decisión propuesta
G1 Captura	Par UVC real, FPS medidos, timestamps, compresión	Elegir 1080p captura con 720p compute o 720p nativo; calibrar modo físico final
G2 Calibración	Reproyección, y-error, distancia por rango, estabilidad	Repetir/fijar calibración; comparar modelos de distorsión si bordes malos
G3 Baselines	B0–B4 sobre split independiente	Decidir si hay espacio real para fusión aprendida
G4 Fusion	Error vs B4, confianza, generalización	Ajustar alineación, arquitectura o pérdida; conservar resultados negativos
G5 Teachers	Accuracy + costo Fast-FoundationStereo/MonSter	Usar como referencia, pseudo-label o entrada solo si muestra complemento

Gate	Condición a comprobar	Decisión propuesta
G6 Tiempo real	p95 captura–bip y consulta–audio medidos	Determinar inferencia a pedido, frecuencias y necesidad de Lite
G7 GUI comparativa	Los mapas etiquetados por frame y unidad	Habilitar comparación “live” y “replay” sin mezclar fechas
G8 Bluetooth	Reconexión, mic, simultaneidad y latencia reales	Decidir HFP vs mic separado; no postergar decisión
G9 Wearable	Power/temperatura, jitter Wi-Fi, cables, pérdida	Declarar objetivo de etapa B alcanzado o dejarlo de extensión
G10 Defensa	Experimentos reproducibles, fallos explicados y cuatro modos	Congelar, presentar beta y anexar backlog personal

14 Demostración ideal para el jurado

14.1 Experimento científico verificable

Montar tres escenas con distancias independientes: objeto texturado en primer plano, pared lisa, zona brillante y bordes/oclusiones. Capturar par estéreo ELP, con frame ID y referencias de distancias. Presentar en pantalla:

1. RGB izquierdo/derecho rectificados y overlay de detecciones.
2. SGBM crudo, DA-V2 (relativo alineado o métrico), regla fija B4, Fusion y Lite si existe. **Misma escala cromática numérica** en mapas comparables.
3. GT físico en los objetos (y GT denso donde esté disponible), error en metros/disparidad, mask válidas, mapa de incertidumbre y confidence-abstain.
4. Comparación tabulada por escena: EPE/bad-2, MAE objeto, cobertura-error, p50/p95 en GPU de demo.
5. Mostrar un caso de mejora, uno de empate y uno donde Fusion empeora. Pregunta: “¿Por qué y cuándo conviene combinar?”

14.2 Experimento aplicado en vivo

Usuario: “Buscá mi mochila” → detección confirmada y bip → dirección/metros si confiable → “guiame” → usuario gira hacia el lado equivocado → objeto se pierde → suspensión de guía y reinicio de búsqueda. Luego consulta distancia de silla, descripción del entorno y lectura de cartel. Mostrar en el dashboard la máquina de estados y eventos, no solo video.

14.3 Argumento de defensa sugerido

> *“VisionX investiga si una fusión neuronal compacta de geometría estéreo y priors monoculares puede mejorar distancias y, sobre todo, expresar cuándo esas distancias son fiables. Comparamos nuestra red contra métodos clásicos, fusión sin aprendizaje y redes estéreo modernas. Convertimos los resultados en cuatro modos de asistencia auditiva sobre una cámara USB real, con latencia y fallos medidos.”*

14.4 Preguntas difíciles que conviene responder antes de presentar

1. ¿Qué es genuinamente propio frente a MonSter y DEFOM-Stereo?
2. ¿Por qué una CNN residual de fusión y no Fast-FoundationStereo directamente?
3. ¿Por qué el error de disparidad no basta para demostrar metros correctos?
4. ¿Qué relación existe entre b de Laplace y cobertura real de intervalos?
5. ¿Cómo evita fuga de datos entre entrenamiento, validación y evaluación de ELP?
6. ¿Qué mide el dashboard al mover la cámara: mapa por frame o mundo 3D acumulado?
7. ¿Qué ocurre cuando el objetivo sale de cámara y no hay IMU?
8. ¿Cuál es el presupuesto de latencia real de bip, voz y render?
9. ¿Qué falla al conmutar perfiles Bluetooth y qué fallback hay?
10. ¿Cómo se demuestra que ambos autores entienden y revisaron código generado por IA?

15 Riesgos, integridad científica, privacidad y condiciones de uso

15.1 Riesgos técnicos prioritarios

Riesgo	Evidencia de diagnóstico	Mitigación / decisión
Fusion no mejora B4	Error test por zonas y CI	Revisar alineación, masks, normalización; documentar resultado nulo
Teacher supera Fusion por mucho	Benchmark igualado	Puede ser baseline; concentrar aporte en incertidumbre / eficiencia
Incertidumbre sobreconfiada	AUSE, interval coverage, abstención	Recalibración y selección por validación
Frames estancados	Edad de timestamp/colas	Último frame, cancelar trabajos obsoletos
Falsos hallazgos	Falsos bips/min y track switches	Confirmación temporal, prioridad cancelación
Audio bidireccional falla	Loopback y perfil del dispositivo	Mic separado, USB, fallback offline
GPU MPS no soporta repo	Import, infer, profiling	Mover solo teacher a CUDA/VM, no romper demo
Datos con fuga	Hash de escenas/sesiones	Manifests, splits independientes, test final sellado
Consumo y calor Pi	30 min y power logs	Fuente adecuada, caja ventilada, aliviar cable

15.2 Accesibilidad y seguridad

No presentar alertas de cercanía como sistema certificado de navegación o sustituto del bastón. Pruebas con ojos vendados solo con supervisión y control de riesgos. Si se realizan estudios con participantes, consultar requisitos éticos de la universidad y obtener consentimiento. No identificar rostros, y explicitar si las imágenes se envían a VLM externos; permitir demo local sin enviar escenas privadas.

15.3 Uso de IA en el desarrollo

Distinguir código sugerido por IA de resultados ejecutados, mantener revisión humana de cada PR, referencias reales a papers, registro de experimentos, trazabilidad de prompts cuando la política lo permita y capacidad de explicar matemáticamente módulos neuronales. Consultar por escrito las condiciones específicas del curso; evitar afirmar prohibiciones que la consigna revisada no detalla.

16 Agenda de contraste para Claude: decisiones abiertas

A continuación se sugieren preguntas que deberían formar parte del artifact final, con respuestas contrastables y una opción de *no incorporar*. No son instrucciones imperativas.

1. ¿Conviene la hipótesis *precisión + confianza + eficiencia* como contribución principal, o una formulación alternativa aún más novedosa?
2. ¿Cuáles papers de 2025/2026 son indispensables? ¿Hay otros modelos publicados hasta 28/10/2026 con mejor compromiso para stereo real-time? Presentar evidencia, licencia y reproducibilidad.
3. ¿La estrategia de alineación robusta relativa $d \approx sm + t$ es suficiente? ¿Cómo comparar frente al checkpoint métrico de DA-V2?
4. ¿Qué representación entrenar con datasets heterogéneos: disparidad nativa normalizada físicamente, profundidad inversa, profundidad métrica o doble cabeza? ¿Qué metadatos faltan?
5. ¿Qué arquitectura de Fusion conviene: residual simple, residual con gate, expert mixing o alternativa recurrente? ¿Cuántos modelos entrenar sin perjudicar conclusiones?
6. ¿La incertidumbre Laplace es suficiente? ¿Se requieren ensemble, evidential, quantile o conformal intervals como test adicional? Diferenciar incertidumbre epistemológica y aleatoria.
7. ¿Cómo definir GT de objetos extensos y evitar que el mismo calibrado sea validación exclusiva?
8. ¿Cómo construir dashboard de cuatro mapas y nube 3D con no bloqueo, timestamps y replay?
9. ¿Qué benchmarks justos incluir entre SGBM, WLS, DA-V2, B4, Fusion, Lite, FoundationStereo, Fast-FoundationStereo, MonSter y DEFOM?
10. ¿Cuáles submódulos producen dependencia temporal fuerte? ¿Qué mocks y contratos los desacoplan?

11. ¿Qué hardware y plataforma usa cada integrante? ¿Qué es local Mac MPS vs CUDA VM y qué costos de integración real tiene?
12. ¿Qué riesgos funcionales no se detectarán hasta probar Bluetooth, Wi-Fi y cancelación en la primera semana?
13. ¿Qué parte de Near Object Alert puede evaluarse sin prometer navegación segura?
14. ¿Qué resultados mínimos constituyen beta académicamente completa y qué tareas deben permanecer abiertas como proyecto posterior?

Idea a contrastar

Formato de devolución sugerido para Claude: una tabla `ID / recomendación / acuerdo o desacuerdo / evidencia y link / experimento / decisión / owner / dependencia / impacto en cronograma`, seguida de un *Plan VisionX vNext* que conserve todo lo válido del artifact y no introduzca contradicciones sin señalarlas. Solicitar explícitamente evidencia nueva y objeciones, no aprobación por cortesía.

17 Bibliografía anotada y enlaces verificables

Las entradas [Rxx] son fuentes externas verificadas o documentación oficial; [S1–S2] son archivos aportados. Las referencias explican *por qué leer cada fuente*; no afirman que el proyecto reproduzca sus métricas. En el artifact final usar formato bibliográfico compatible con IEEE.

[S1] Plan VisionX (2026), 31 páginas, PDF provisto por el equipo, 28/10/2026. Documento de base para decisiones ya consideradas y roadmap. *Sin URL de acceso garantizado fuera de esta conversación.*

[S2] Trabajo Práctico Final, I308 Visión Artificial, UdeSA, versión 26.23.10. Fuente oficial para entregables, cantidad de páginas, grupos y aprobación de tema. Documento local aportado.

[R01] Hirschmüller, H. (2008). "Stereo Processing by Semiglobal Matching and Mutual Information". IEEE TPAMI. DOI. *Base geométrica y semiglobal.*

[R02] Yang, L. et al. (2024). "Depth Anything V2". NeurIPS. paper; código. *Prior monocular principal.*

[R03] Cheng, J. et al. (2025). "MonSter: Marry Monodepth to Stereo Unleashes Power". CVPR. paper; código. *Prior art directo de fusión.*

[R04] Jiang, H. et al. (2025). "DEFOM-Stereo: Depth Foundation Model Based Stereo Matching". CVPR. paper; código. *Priorización de features monoculares y escala.*

[R05] Wen, B. et al. (2025). "FoundationStereo: Zero-Shot Stereo Matching". CVPR. paper; código. *Comparador robusto y teacher.*

[R06] Wen, B.; Dewan, S.; Birchfield, S. (2026). "Fast-FoundationStereo: Real-Time Zero-Shot Stereo Matching". CVPR, pp. 7513–7524. paper. *Comparador reciente crítico.*

[R07] NVIDIA NVLabs (2026). Fast-FoundationStereo (repositorio), tabla de checkpoints y latencias en RTX 3090. *Métricas reportadas, no extrapolar a VisionX.*

[R08] Lipson, L. et al. (2021). "RAFT-Stereo: Multilevel Recurrent Field Transforms for Stereo Matching". 3DV. preprint y bibliografía. *Baseline neuronal recurrente.*

[R09] Batsos, K.; Mordohai, P. (2018). "RecResNet: A Recurrent Residual CNN Architecture for Disparity Map Enhancement". 3DV. paper (PDF). *Antecedente de refinamiento residual.*

[R10] Poggi, M. et al. (2022). "On the Confidence of Stereo Matching in a Deep-Learning Era". IEEE TPAMI. DOI. *Comparación de confianza estéreo.*

[R11] Kendall, A.; Gal, Y. (2017). "What Uncertainties Do We Need in Bayesian Deep Learning for Computer Vision?". NeurIPS. paper. *Pérdidas heteroscedásticas.*

[R12] Depth Anything Team (2024–2026). Documentación de modelos métricos indoor/outdoor. *Diferencia relativa/métrica y pesos de Small.*

[R13] Bao, W. et al. (2020). "InStereo2K: A Large Real Dataset for Stereo Matching in Indoor Scenes". Science China Information Sciences. dataset oficial. *2000 train/50 test, disparidad PNG/100.*

[R14] Schöps, T. et al. (2017). "A Multi-View Stereo Benchmark with High-Resolution Images and Multi-Camera Videos". CVPR. ETH3D benchmark. *GT láser y datos externos.*

[R15] Scharstein, D. et al. (2014). "High-Resolution Stereo Datasets with Subpixel-Accurate Ground Truth". GCPR. Middlebury dataset y convención doffs. *Calibración y benchmark.*

[R16] OpenCV (documentación actual). Stereo y reprojectImageTo3D. *Conversión Q y disparidad SGBM.*

[R17] Zama Ramirez, P. et al. (2022). "Open Challenges in Deep Stereo: The Booster Dataset". CVPR. paper. *Vidrio, reflejos y GT difícil.*

[R18] Mayer, N. et al. (2016). "A Large Dataset to Train Convolutional Networks for Disparity, Optical Flow, and Scene Flow Estimation". CVPR. dataset/paper. *Fuente sintética si se requiere.*

[R19] ELP (ficha oficial). ELP-USB3D1080P02-H120. *UVC USB 2.0, JX-F35, MJPEG, FPS nominales, consumo.*

[R20] Raspberry Pi Ltd. Documentación de hardware Pi 5. *Presupuesto de alimentación periférica USB.*

[R21] PyTorch MPS backend macOS y Apple Metal PyTorch. *Compatibilidad de Mac Apple Silicon.*

[R22] Ronneberger, O. et al. (2015). "U-Net: Convolutional Networks for Biomedical Image Segmentation". MICCAI. paper. *Antecedente del encoder-decoder con skip connections.*

[R23] Hinton, G.; Vinyals, O.; Dean, J. (2015). "Distilling the Knowledge in a Neural Network". paper. *Fundamentos de teacher-student.*

[R24] OpenCV ChArUco y calib3d. *Método de calibración y evaluación geométrica.*

Nota final para el intercambio entre asistentes

Este documento propone ampliar el **rigor y la ambición**, no complicar artificialmente VisionX. El mejor resultado podría ser una red propia que gana en regiones difíciles, una incertidumbre mejor calibrada y una demo de cuatro modos estable; o una investigación sólida que encuentre que un baseline externo es superior y explique cómo la incertidumbre, eficiencia o el uso físico agregan valor. **No modificar resultados para sostener una narrativa previa.** Investigar, medir, decidir y conservar rutas de evolución posteriores al TPF.