VisionX

Anteojos con cámara estéreo que le dicen a una persona ciega dónde están las cosas

I308 Visión Artificial · UdeSA · Primavera 2026 · Propuesta de tema libre · [Nombre 1], [Nombre 2]

Una persona con baja visión necesita saber **dónde** está un objeto, **a qué distancia** y **qué tiene enfrente**, sin mirar una pantalla. VisionX es una cámara estéreo, la ELP-USB3D1080P02 (en adelante, la ELP), montada en anteojos y conectada a una notebook. La persona aprieta un botón, habla, y el sistema responde por voz.

Qué se le puede pedir

“¿Dónde están mis llaves?”
Avisa con un bip cuando lo ve y guía con frases cortas hasta tenerlo enfrente.

“¿Qué tan lejos está la puerta?”
“A dos metros, más o menos.” Si no está seguro, lo dice.

“¿Qué hay adelante?”
Describe la escena usando objetos y distancias que el sistema midió.

“Leeme esto.”
Lee carteles y etiquetas, y guía el encuadre si el texto está cortado.

El aporte de visión artificial

Para decir distancias hace falta profundidad confiable. Hay dos fuentes con fallas opuestas:

- **Estéreo clásico.** SGBM (*Semi-Global Block Matching*), un algoritmo de OpenCV, compara las dos imágenes y mide metros reales por geometría, pero falla en paredes lisas, bordes y reflejos.
- **Profundidad monocular.** Depth Anything V2, una red preentrenada, estima la forma de toda la escena con una sola imagen, pero no sabe la escala.

Proponemos **SpatialDepth-Fusion** (en adelante, **Fusion**), una red propia que aprende a combinarlas píxel a píxel y que además estima cuánto confía en cada valor. Después la destilamos, es decir, entrenamos una red más chica con sus salidas: **SpatialDepth-Lite** (en adelante, **Lite**), una versión liviana para correr en continuo.

Fusionar monocular y estéreo ya fue estudiado con redes grandes, como MonSter y DEFOM-Stereo. Lo nuevo es probarlo con una red compacta sobre una cámara USB de bajo costo, y medir si su incertidumbre sirve para saber cuándo callarse.

> **Hipótesis.** La fusión aprendida tiene menos error que cada fuente sola y que una regla fija de combinación, sobre todo en bordes, oclusiones y superficies sin textura. Y su incertidumbre permite callarse cuando no sabe, lo que baja el error de las distancias que sí anuncia.

En la página siguiente está el flujo completo. Cada marca numerada se explica después.

Prototipo académico. No reemplaza al bastón, al perro guía ni a tecnologías validadas clínicamente.

Flujo del sistema

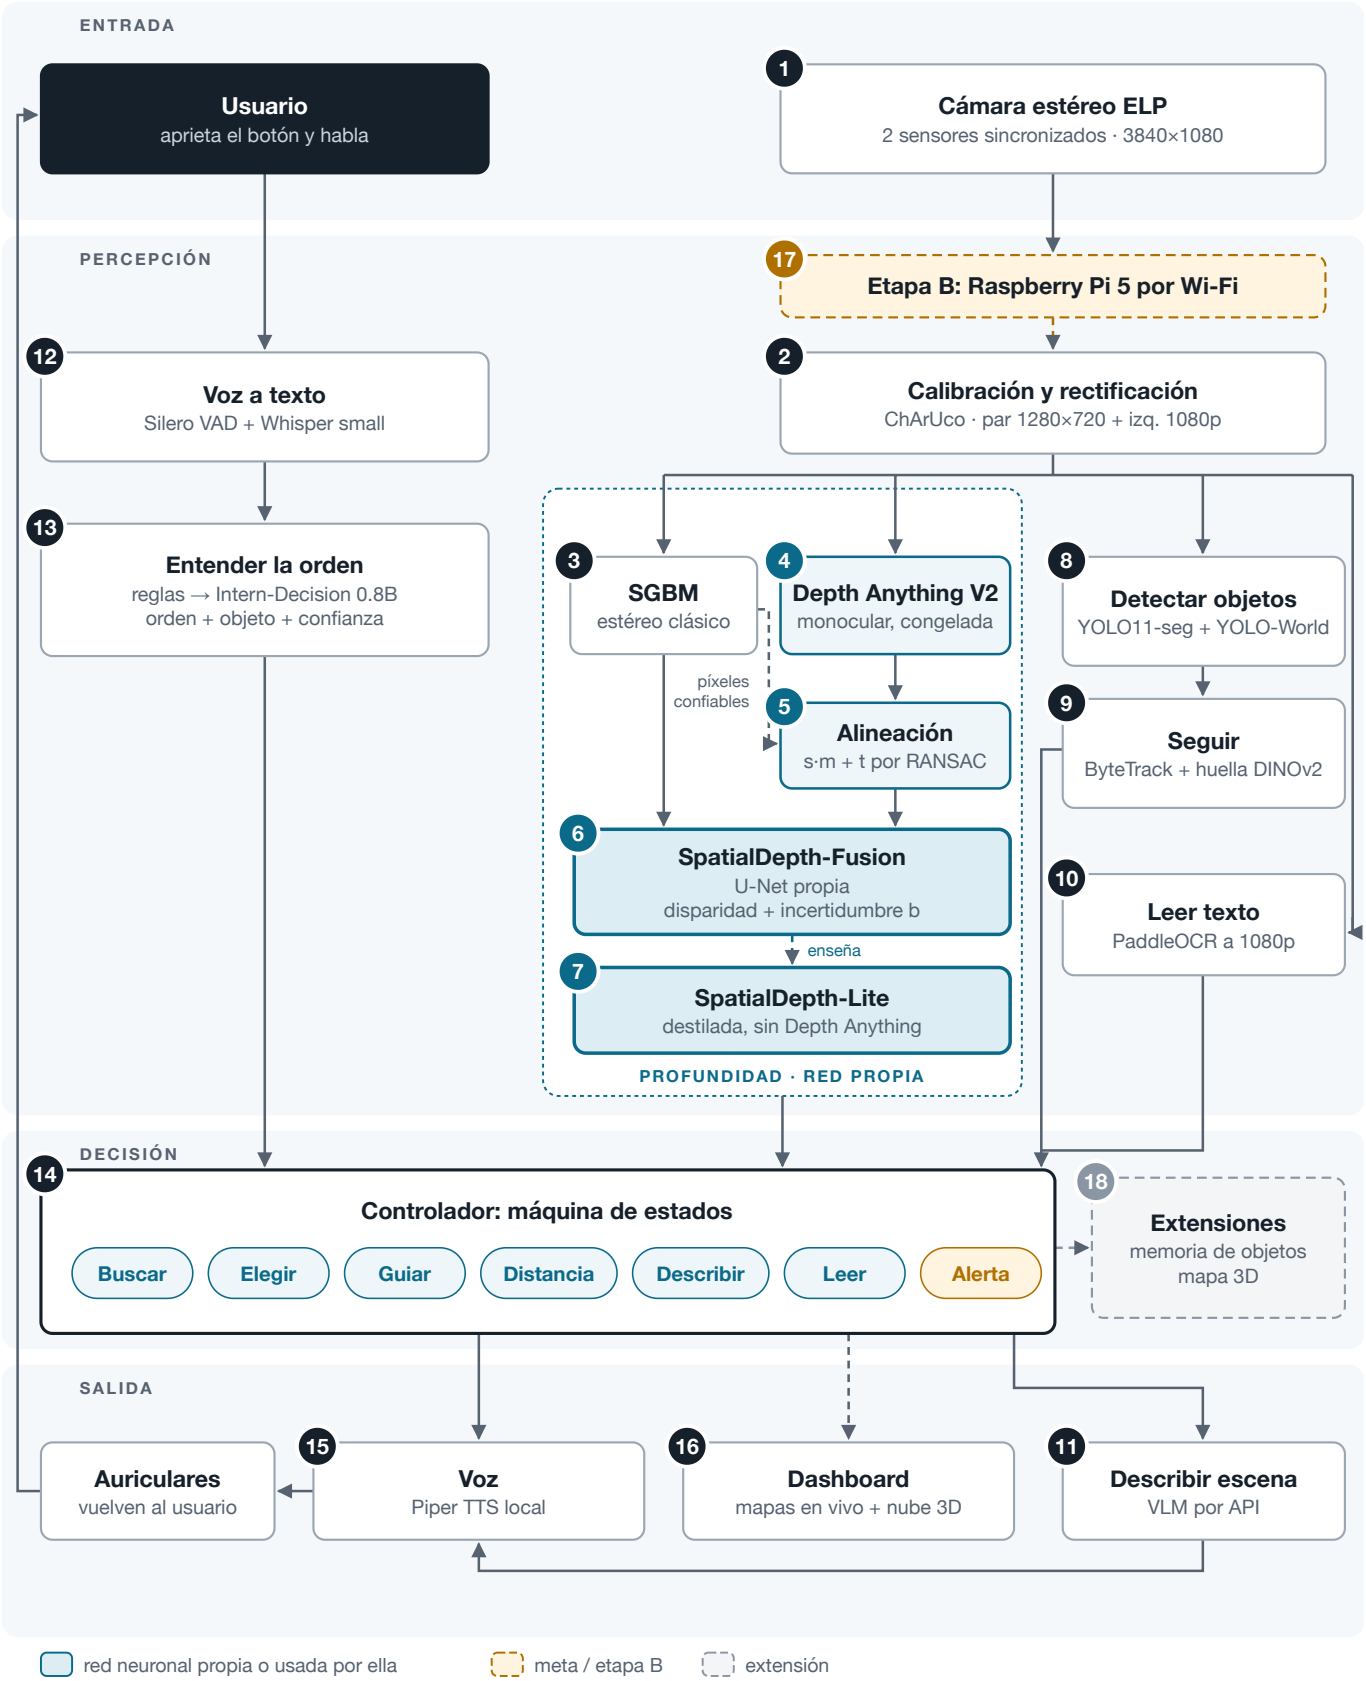


Figura 1. Flujo del sistema, de arriba hacia abajo. La voz (izquierda) y la imagen (derecha) se procesan en paralelo y llegan al controlador, que decide según el modo. La respuesta vuelve por voz, y el dashboard muestra todo en pantalla para evaluar. En azul, la parte de redes, que es el aporte del trabajo. Siglas: VAD, detector de actividad de voz; TTS, síntesis de voz; OCR, reconocimiento óptico de caracteres; VLM, modelo de visión y lenguaje; RANSAC, ajuste robusto que ignora valores atípicos; b, incertidumbre estimada por Fusion (marca 6). Los modelos con nombre propio se presentan en la ficha de cada marca.

Un recorrido: “¿dónde está mi celular?”

1. La persona aprieta el botón y habla. 12 transcribe y 13 entiende *buscar(celular)*.
2. El controlador 14 pasa a **Buscar**. 8 detecta tres celulares sobre la mesa y 9 los sigue.
3. Como hay varios, pasa a **Elegir**: *“Veo tres celulares: izquierda, enfrente y derecha. ¿Cuál es el tuyo?”* La persona contesta *“el de funda roja”*. 11 distingue cuál es y 13 resuelve la respuesta.
4. Pasa a **Guiar**. 6 da la distancia dentro de la silueta del objeto y 15 dice *“a la derecha, a un metro”*.
5. Cada 1,5 s actualiza hasta que la persona lo tiene enfrente: *“Lo tenés adelante, a 30 centímetros.”* Si gira para el otro lado y lo pierde: *“Lo perdí de vista, sigo buscando.”*

Qué es cada marca

1 Cámara estéreo ELP-USB3D1080P02

Dos sensores sincronizados que salen lado a lado en una sola imagen de 3840×1080, comprimida como MJPEG (cada cuadro, un JPEG) por USB 2.0. La separación entre lentes, que llamamos B, es de unos 59 mm, y la distancia focal en píxeles, f, de unos 606 px.

Si llamamos d a la disparidad, la diferencia de columnas con que un punto aparece en cada imagen, su profundidad Z sale de $Z = f \cdot B/d$. El error crece con el cuadrado de la distancia: 4 cm a 1 m, 17 cm a 2 m. Por eso el rango de uso es de 0,5 a 3 m.

2 Calibración y rectificación

Tablero ChArUco (un damero con marcadores numerados) de 11×8 cuadrados de 30 mm, en A3. Intrínsecos por cámara, luego estéreo con intrínsecos fijos, y rectificación. Se usan tres sets: calibrar (60 a 80 vistas), validar (20, nunca usadas para calibrar) y distancias a 1, 2 y 3 m medidas con cinta.

Salen dos imágenes: el par rectificado reducido a 1280×720 para profundidad, y la imagen izquierda a 1080p para detectar y leer. Metas: error de reproyección menor a 0,3 px y escala con menos de 0,5 % de error. El mismo tablero da la profundidad verdadera para evaluar en nuestra cámara.

3 SGBM: estéreo clásico

SGBM con chequeo de consistencia entre la imagen izquierda y la derecha. Da metros reales.

Falla en paredes lisas, bordes, zonas tapadas para un ojo y reflejos. Además de la disparidad, aporta mapas de validez, consistencia y error que usa la red.

4 Depth Anything V2 Small

Red preentrenada (NeurIPS 2024, 24,8 M de parámetros, licencia Apache-2.0) que estima profundidad con una sola imagen. Se usa congelada, sin reentrenar.

Entiende la forma de la escena en todas partes, incluso donde SGBM falla, pero no sabe la escala: no da metros.

5 Alineación

Lleva la salida de Depth Anything a la escala de SGBM con $d \approx s \cdot m + t$, donde m es la salida de Depth Anything, y s y t una escala y un corrimiento ajustados con RANSAC sobre los píxeles donde SGBM es confiable.

Si hay menos de 500 píxeles confiables, el frame se marca como no alineado.

6 SpatialDepth-Fusion: el aporte principal

U-Net propia (una red convolucional que achica y vuelve a agrandar la imagen) de unos 2 M de parámetros, que recibe 10 canales: imagen, SGBM y sus mapas de confianza, y Depth Anything alineado. Aprende píxel a píxel cuándo creerle a cada fuente.

Predice una corrección sobre una regla fija (SGBM si es confiable, si no Depth Anything), así que arranca igual a esa regla y lo que aprende es la corrección. Una segunda salida estima, para cada píxel, cuánto espera equivocarse la red: el parámetro de escala de una distribución de Laplace alrededor de la disparidad predicha. A esa incertidumbre la llamamos *b*. Cuando b es alta, el sistema dice “no estoy seguro” en vez de inventar metros. Se entrena con InStereo2K y se evalúa en Middlebury y ETH3D, datasets públicos de pares estéreo con profundidad medida, y en nuestra cámara. Fusionar mono y estéreo ya existe (MonSter, DEFOM-Stereo): lo propio es hacerlo con una red chica, con incertidumbre calibrada y en una cámara USB barata. Una variante, que llamamos **Fusion-FFS**, aplica la misma red sobre la disparidad de Fast-FoundationStereo, una red estéreo reciente (CVPR 2026), para ver si la red todavía mejora el error y la incertidumbre.

7 SpatialDepth-Lite: destilación

La misma red sin Depth Anything, que es lo más caro de correr. Fusion le enseña como red maestra usando unos 5 000 pares de video propio sin etiquetar, descartando lo que Fusion marca como incierto.

Lite corre en continuo (alerta, wearable). Fusion se usa en pedidos puntuales, como medir una distancia.

8 Detectar objetos

YOLO11n-seg, un detector y segmentador en tiempo real, para las 80 clases comunes del dataset COCO. YOLO-World, un detector al que se le da el nombre del objeto como texto, para objetos fuera de esa lista, como “llaves” o “billetera”, nombrados por texto.

Un objeto cuenta como visto si aparece en 3 de 5 frames, para evitar falsos avisos.

9 Seguir el objeto

ByteTrack, un algoritmo de seguimiento, le da a cada objeto un número estable entre frames. Para el objeto elegido se guarda además una huella: 384 números que describen su apariencia, calculados con DINOv2, una red de visión preentrenada, con la que se lo reconoce si se pierde y vuelve.

Si el objeto sale de cuadro, la guía se suspende y vuelve a buscar. Sin sensor de movimiento no se inventa dónde quedó. Con varios iguales: “Veo tres celulares: izquierda, enfrente y derecha. ¿Cuál es el tuyo?”

10 Leer texto

Elige el frame más nítido y lo pasa a PaddleOCR, una librería de OCR, a 1080p.

Si el texto está cortado o borroso, guía el encuadre: “movelo a la izquierda”, “acercalo”.

11 Describir escena (VLM)

Modelo de visión y lenguaje, consultado por internet. Recibe la imagen y la lista de objetos que ya medimos (qué son, dónde están, a qué distancia), para que no invente.

También distingue objetos repetidos con recortes numerados (“el de funda roja”). Sin conexión responde con una plantilla. No identifica caras.

12 Voz a texto

Botón para hablar (barra espaciadora o control Bluetooth). Silero, un VAD, detecta cuándo termina la frase, y faster-whisper small, una versión optimizada del reconocedor de voz Whisper, la transcribe, con una lista de órdenes y objetos para que acierte más.

13 Entender la orden

Primero reglas simples (“buscá X”, “¿qué tan lejos?”). Si no alcanzan, Intern-Decision 0.8B, un modelo de decisión abierto que corre en la notebook, elige la orden entre opciones fijas y da su probabilidad. Si la probabilidad es menor a 70 %, repregunta.

Se prueba primero con 50 frases. Si no rinde, la alternativa es un modelo de lenguaje general (LLM) por internet que devuelve la orden en formato JSON.

14 Controlador

Máquina de estados que coordina todo. Cada servicio corre en su hilo y lee siempre el último frame. Una cola de audio con prioridades permite cortar con el botón en cualquier momento.

Buscar: bip apenas lo ve, luego dirección y distancia. **Elegir:** si hay varios iguales, pregunta cuál. **Guiar:** actualiza cada 1,5 s. **Distancia:** redondea según la incertidumbre. **Describir** y **Leer**. **Alerta** (meta): avisa de obstáculos cercanos con Lite y el plano del piso. Antes de hablar, un único criterio de confianza decide entre decir metros, decir solo la dirección, pedir reencuadrar o abstenerse.

15 Voz

Piper, un TTS neuronal, corre en la notebook. Las frases frecuentes quedan pregrabadas para responder sin demora.

16 Dashboard

Pantalla para el equipo y el jurado, no para el usuario. Muestra en vivo la imagen con detecciones, SGBM, Depth Anything, Fusion con su incertidumbre y Lite, cada mapa con su edad y tiempo de cálculo. Incluye la nube de puntos 3D del frame actual.

Tiene dos modos: **en vivo**, donde cada mapa va a su ritmo, y **replay**, donde todos los métodos procesan el mismo frame grabado para compararlos de forma justa. La nube 3D es por frame: acumular un mapa requiere estimar el movimiento y queda como extensión.

17 Wearable (etapa B)

Una Raspberry Pi 5 envía el video por Wi-Fi de 5 GHz a la notebook y recibe el audio. Siempre manda el último frame y descarta los viejos. Se prueban temprano los AirPods: el micrófono por Bluetooth cambia de perfil y puede degradar el audio.

Se hace si llegamos. Se mide la latencia contra el cable USB.

18 Extensiones

Memoria de objetos (“¿dónde dejé las llaves?”), registrar objetos propios por su huella, y un mapa 3D de la habitación.

Cómo se evalúa la red

Qué	Detalle

Datos	InStereo2K (2 050 pares de interiores) para entrenar y validar. Middlebury 2014 (23 pares), ETH3D (27 pares) y 30 a 50 escenas propias con el tablero para testear.
Contra qué se compara	SGBM solo, SGBM con un filtro de suavizado WLS (mínimos cuadrados ponderados), Depth Anything alineado solo y métrico, y la regla fija de combinación, que es el rival principal. FoundationStereo y Fast-FoundationStereo, redes estéreo grandes, como techo. Todos sobre los mismos frames y el mismo hardware.
Métricas	Error promedio de disparidad y porcentaje de píxeles con más de 2 px de error, en cuatro zonas: global, bordes, oclusiones y sin textura. Error en metros por rango. Porcentaje de píxeles con respuesta, para que nadie gane descartando lo difícil. Calidad de la incertidumbre: si ordena bien los errores y si sus intervalos contienen el valor real. Latencia mediana y P95.
Ablaciones	Sin canales monoculares, sin RGB, sin canales clásicos, sin incertidumbre, con y sin una compuerta que limite la corrección, con y sin aumentos que imiten la compresión de la ELP, y Lite con y sin destilación.
Variante	Fusion-FFS: la misma red con Fast-FoundationStereo en lugar de SGBM, comparada contra Fast-FoundationStereo solo.
En la cámara real	Distancia a 10 objetos a 1, 2 y 3 m, con y sin abstención.

> **Criterio de éxito, fijado antes de entrenar.** Fusion le gana a la mejor alternativa en bordes, oclusiones y zonas sin textura. Y en nuestra cámara, callarse cuando la incertidumbre es alta reduce el error de las distancias anunciadas. También se muestran los casos donde Fusion empeora.

Referencias principales

1. Hirschmüller. Stereo processing by semiglobal matching and mutual information. TPAMI, 2008.
2. Zhang. A flexible new technique for camera calibration. TPAMI, 2000.
3. Garrido-Jurado et al. Automatic generation and detection of highly reliable fiducial markers. Pattern Recognition, 2014.
4. Yang et al. Depth Anything V2. NeurIPS, 2024.
5. Ronneberger et al. U-Net. MICCAI, 2015.
6. Kendall, Gal. What uncertainties do we need in Bayesian deep learning for computer vision? NeurIPS, 2017.
7. Hinton et al. Distilling the knowledge in a neural network. NeurIPS Workshop, 2015.
8. Poggi et al. On the confidence of stereo matching in a deep-learning era. TPAMI, 2022.
9. Cheng et al. MonSter: Marry monodepth to stereo unleashes power. CVPR, 2025.
10. Wen et al. FoundationStereo. CVPR, 2025.
11. Bao et al. InStereo2K. Sci. China Inf. Sci., 2020.
12. Scharstein et al. High-resolution stereo datasets with subpixel-accurate ground truth. GCPR, 2014.
13. Schöps et al. A multi-view stereo benchmark. CVPR, 2017.
14. Jiang et al. DEFOM-Stereo. CVPR, 2025.
15. Wen et al. Fast-FoundationStereo. CVPR, 2026.
16. Cheng et al. YOLO-World. CVPR, 2024.
17. Zhang et al. ByteTrack. ECCV, 2022.
18. Oquab et al. DINOv2. TMLR, 2024.
19. Radford et al. Robust speech recognition via large-scale weak supervision. ICML, 2023.

Sin referato: Intern-Decision (arXiv, 2026), PaddleOCR y Piper (documentación técnica).